

Chapitre I

Bases théoriques

Dans cette leçon, nous (re)verrons les bases de l'optimisation dans des espaces continus :

- la caractérisation d'un minimum/maximum local/global,
- la différentiabilité et les dérivées partielles,
- le théorème de Taylor,
- le calcul de dérivées numériques,
- la convexité et comment déterminer si une fonction est convexe,
- les propriétés utiles sur les matrices dans ce cadre.

Rappel : ce cours reprend largement l'excellent cours d'optimisation de Max Cerf (Université Paris 6 / Ariane Espace).

1 Formulation

Formulation mathématique d'un problème optimisation (PO) sous forme standard

$$\min_{x \in \mathbb{R}^n} f(x) \text{ sous } \begin{cases} c_E(x) = 0 \\ c_I(x) \leq 0 \\ x \in X \end{cases}$$

Notations

- x : n **variables** (ou paramètres / inconnues) $\rightarrow$ vecteur de $\mathbb{R}^n$
- f : **critère** (ou fonction coût / objectif) $\rightarrow$ fonction de $\mathbb{R}^n$ dans $\mathbb{R}$
- c_E : p **contraintes d'égalité** $\rightarrow$ fonction de $\mathbb{R}^n$ dans $\mathbb{R}^p$
= vecteur de p fonctions de $\mathbb{R}^n$ dans $\mathbb{R}$
- c_I : q **contraintes d'inégalité** $\rightarrow$ fonction de $\mathbb{R}^n$ dans $\mathbb{R}^q$
= vecteur de q fonctions de $\mathbb{R}^n$ dans $\mathbb{R}$
- X : ensemble convexe $X \subseteq \mathbb{R}^n$ (**valeurs admissibles des variables**)

Exemple :

$$\min_{(x,y,z) \in \mathbb{R}^3} x^2 + y^2 - 3z^3 + 3 \quad \text{sous } \begin{cases} x + 2y = 3 \\ 2x - 3z \leq 4 \\ (x, y, z) \in [0, 2] \times [-3, 3] \times [1, 4] \end{cases}$$


1.1 Problèmes équivalents

L'idée d'un problème équivalent est de transformer le problème ou les contraintes :

- pour retrouver la forme canonique d'un problème d'optimisation,
- pour transformer le problème en un problème équivalent.

Problèmes équivalents

(PO₁) et (PO₂) sont deux problèmes équivalents si on peut associer à tout point admissible x_1 de (PO₁) un point admissible x_2 de (PO₂) avec la même valeur pour le critère.



Ils ont alors des solutions de même coût : $f_1(x_1^*) = f_2(x_2^*)$.

Exemples de transformations simples

- Changement de variable : $y = \varphi(x)$ avec φ strictement monotone sur X
- Maximisation / minimisation : $\max_x f(x) \Leftrightarrow \min_x (-f(x))$
- Contrainte inférieure / supérieure : $c(x) \geq 0 \Leftrightarrow -c(x) \leq 0$
- Variables libres $\rightarrow$ variables positives : $x = x^+ - x^-$ avec $x^+, x^- \in \mathbb{R}^+$
- Contrainte d'inégalité $\rightarrow$ égalité + variable d'écart :
 $c(x) \leq 0 \Leftrightarrow c(x) + y = 0$ avec $y \geq 0 \Leftrightarrow c(x) + z^2 = 0$ avec $z \in \mathbb{R}$

1.2 Hypothèses

Afin d'adopter une première analyse mathématique du problème, on fera les hypothèses suivantes :

Hypothèses

- **Continuité** : Fonctions continues de variables réelles
 $\Rightarrow$ Optimisation continue
 $\neq$ Optimisation combinatoire, Programmation en nombres entiers
- **Différentiabilité** : Fonctions différentiables
 $\Rightarrow$ **Méthodes à base de gradient** $\neq$ Méthodes sans dérivées
- **Déterminisme** : Les données du problème sont parfaitement connues
 $\neq$ Optimisation stochastique

Cas étudiés

- Programmation linéaire : coût linéaire et contraintes linéaires (*LP*)
- Programmation quadratique : coût quadratique et contraintes linéaires (*QP*)
- **Programmation non linéaire : cas général, fonctions quelconques** (*NLP*)

On reverra donc les notions de base de différentiabilité dans $\mathbb{R}^n$.

1.3 Normes

a) Normes vectorielles


On minimise en général un critère, et ce critère consiste souvent en la minimisation d'une distance.

On rappelle la définition des différentes normes utilisées pour mesurer des distances :

Norme vectorielle sur $\mathbb{R}^n$

- Une norme est une fonction $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}$ vérifiant

$$\begin{cases} \|x\| \geq 0 \\ \|x\| = 0 \Leftrightarrow x = 0 \\ \|x + y\| \leq \|x\| + \|y\| \\ \|\alpha x\| = |\alpha| \|x\| \end{cases}$$
- Norme p : $\|x\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$
- **Norme ∞** : $\|x\|_\infty = \max_{i=1, \dots, n} |x_i|$
- **Norme 2 = norme euclidienne** (distance classique)



b) Normes matricielles

On peut également définir une norme sur une matrice.

La norme matricielle sur une matrice de taille $m \times n$ est définie de la manière suivante :

- Norme induite sur $\mathbb{R}^{m \times n}$ par la norme vectorielle $\| \cdot \|$
- Fonction $\| \cdot \|_{m \times n} : \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ définie par $\|A\|_{m \times n} = \max_{x \in \mathbb{R}^n, x \neq 0} \frac{\|Ax\|}{\|x\|} = \max_{x \in \mathbb{R}^n, \|x\|=1} \|Ax\|$
à savoir l'étirement maximal que l'application linéaire A peut produire sur la sphère unité.
- Interprétation dans des cas particuliers :
 - ◇ en norme 2 : plus grande valeur singulière.
 - ◇ en norme 1 : max des normes 1 des colonnes.
 - ◇ en norme $+\infty$: max des normes 1 des lignes.

2 Caractérisation des solutions

2.1 Minima locaux et globaux


Comment caractériser un minimum local/global ?

Minimum global (= meilleure solution dans l'absolu)

- x^* minimum global de $(PO) \Leftrightarrow \forall x \in X_{adm}, f(x^*) \leq f(x)$
- x^* minimum global strict $\Leftrightarrow \forall x \in X_{adm}, f(x^*) < f(x)$ si $x \neq x^*$

Minimum local (= meilleure solution dans un voisinage)

- x^* minimum local de $(PO) \Leftrightarrow \exists \varepsilon > 0 / \forall x \in X_{adm}, \|x - x^*\| < \varepsilon, f(x^*) \leq f(x)$
- x^* minimum local strict $\Leftrightarrow \exists \varepsilon > 0 / \forall x \in X_{adm}, \|x - x^*\| < \varepsilon, f(x^*) < f(x)$ si $x \neq x^*$



2.2 Infimum

La notion d'infimum permet de définir le meilleur minimum sur un ensemble.

Soit une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$

Borne inférieure

f bornée inférieurement sur $Y \subseteq \mathbb{R}^n$

$$\Leftrightarrow \exists M \in \mathbb{R} / \forall x \in Y, M \leq f(x)$$

Infimum

- **Infimum de f sur Y** = plus grande borne inférieure sur un ensemble Y .
- **Notation :** $\inf_Y f = \inf \{f(y), y \in Y\}$
- **Propriété :** l'infimum vérifie à la fois
 - ◇ $\forall x \in Y, \inf_Y f \leq f(x)$: c'est une borne inférieure
 - ◇ $\forall M > \inf_Y f, \exists x \in Y / f(x) < M$: il existe au moins un point où la fonction minore toute valeur supérieure à l'infimum.

Rappel : Intervalle compact (= fermé et borné dans $\mathbb{R}^n$)

- sur $\mathbb{R}$, de la forme $[a, b]$. On a $x \in [a, b] \Rightarrow a \leq x \leq b$.
- sur $\mathbb{R}^n$, de la forme $[a_1, b_1] \times \cdots \times [a_n, b_n]$. Si $x = (x_1, \dots, x_n)$ y appartient, alors $a_1 \leq x_1 \leq b_1, \dots, a_n \leq x_n \leq b_n$.

Théorème de Weierstrass

- si Y est compact et f est continue, alors f atteint son infimum sur Y .
 $\exists x^* \in Y / f(x^*) = \inf_Y f$
- ces conditions sont réalisées en pratique : on travaille avec des fonctions continues sur des intervalles fermés
 → Le problème (PO) admet au moins une solution x^* .

3 Différentiabilité

On rappelle que, dans le cadre de l'optimisation continue, nous avons fait l'hypothèse de continuité sur la fonctionnelle à optimiser.

Pourquoi cette hypothèse ?

- soit on veut trouver la solution mathématiquement
alors il faut des critères indiquant que l'on est en train de passer par un minimum.
ceci peut se caractériser par des différentielles.
- soit on veut trouver la solution numériquement
alors il faut un moyen d'y aller, en suivant la "pente" de la fonctionnelle.
on rappelle que les différentielles permettent d'obtenir des informations locales sur la fonctionnelle ce qui permet d'essayer de descendre vers le minimum.

Dans des deux cas, ceci implique une certaine forme de continuité, et de différentiabilité.

On va donc définir pour des fonctions de $\mathbb{R}^n \rightarrow \mathbb{R}$:

- les différentes différentielles (gradient, hessien), et l'intérêt direct qu'elles peuvent avoir,
- les formules de Taylor (développement limité) associées, qui permettent d'obtenir une approximation locale simplifiée de la fonctionnelle.

Par ailleurs, comme on travaille en général sur des données numériques (typiquement sur une grille d'échantillonnage), on verra comment estimer des dérivées numériques.

3.1 Différentielles d'ordre 1

Voyons les définitions des différentielles d'ordre 1 pour une fonction f de $\mathbb{R}^n$ sur $\mathbb{R}$.

Différentiabilité ordre 1 (une fois dérivable) : il suffit que f soit continue.

a) Dérivée partielle

La dérivée partielle de f en x par rapport à x_i est la dérivée dans la direction x_i :

$$\frac{\partial f}{\partial x_i}(x) = \lim_{s \rightarrow 0} \frac{f(x_1, \dots, x_i + s, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{s} \quad (\text{si la limite existe})$$

b) Gradient

Le gradient de f en x , noté $\nabla f(x)$ est le vecteur qui contient l'ensemble des dérivées partielles sur tous les axes.

$$\nabla f(x) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(x) \\ \vdots \\ \frac{\partial f}{\partial x_n}(x) \end{pmatrix} \in \mathbb{R}^n \quad (\text{si toutes les dérivées partielles existent})$$

c) Dérivée directionnelle

La dérivée directionnelle de f en x dans la direction $v \in \mathbb{R}^n$ est la valeur de la dérivée dans cette direction spécifique :

$$D_v f(x) = \lim_{s \rightarrow 0} \frac{f(x + sv) - f(x)}{s} \quad (\text{si la limite existe})$$

noter que $D_v f(x) = v^T \nabla f(x)$ (produit scalaire entre la direction et le gradient).

d) Fonction différentiable et interprétation des dérivées

Une fonction est **différentiable** si et seulement si :

f admet une dérivée directionnelle pour toute direction $d \in \mathbb{R}^n$.

Notes :

- si f est différentiable, alors :
 - ◊ le gradient $\nabla f(\mathbf{x})$ pointe dans la direction de plus forte croissance de f en $\mathbf{x}$.
 - ◊ la norme du gradient $\|\nabla f(\mathbf{x})\|$ est le taux de variation maximal de f en $\mathbf{x}$:

$$\|\nabla f(\mathbf{x})\| = \max_{\|\mathbf{u}\|=1} D_{\mathbf{u}} f(\mathbf{x})$$
 - ◊ si on considère l'hypersurface définie par $\{\mathbf{y} \mid f(\mathbf{y}) = f(\mathbf{x})\}$, alors $\nabla f(\mathbf{x})$ est normale à l'hypersurface passant par $\mathbf{x}$.
- la dérivée directionnelle est la projection de la normale dans la direction choisie.
rappeler ici le sens du produit scalaire.

e) Exercices

EXERCICE 1: Dérivées partielles

Calculer $\frac{\partial f}{\partial x}$ et $\frac{\partial f}{\partial y}$ pour les fonctions suivantes :

1. $f(x, y) = x \cos(x) \sin(y)$
2. $f(x, y) = e^{xy^2}$
3. $f(x, y) = (x^2 + y^2) \ln(x^2 + y^2)$

EXERCICE 2: Calcul du gradient

Calculer le gradient des fonctions suivantes au point p indiqué :

1. $f(x, y) = \sqrt{a^2 - x^2 - y^2}$ en $p = (a/2, a/2)$.
2. $g(x, y) = \ln \sqrt{1 + xy}$ en $p = (1, 1)$.
3. $h(x, y) = e^y \cos(3x + y)$ en $p = (2\pi/3, 0)$.

EXERCICE 3: Calcul des dérivées directionnelles

Calculer les dérivées des fonctions suivantes au point p et dans la direction $\mathbf{v}$:

1. $f(x, y) = x + 2xy - 3y^2$ en $p = (1, 2)$ et dans la direction $\mathbf{v} = (3, 4)$.
2. $g(x, y) = e^{xy} + \arctan y$ en $p = (1, 1)$ et dans la direction $\mathbf{v} = (+1, -1)$.
On rappelle que $(\arctan x)' = 1/(1 + x^2)$.
3. $h(x, y) = \sqrt{x^2 + y^2}$ en $p = (0, 5)$ et dans la direction $\mathbf{v} = (+1, -1)$.

EXERCICE 4: Maximisation d'une dérivée directionnelle

Soit la fonction $f(x, y, z) = xy^2 + z^2y$.

1. Trouver la dérivée de f au point p et dans la direction v où $p = (1, 1, 0)$ et $v = (1, -1, 2)$.
2. Déterminer la direction qui maximise (resp. minimise) la dérivée directionnelle au point $(1, 1, 0)$.
3. Quelles est la plus grande et la plus petite valeur de la dérivée directionnelle en ce point ?

EXERCICE 5: Plan tangent

Calculer le plan tangent à la surface au point indiqué.

1. $x^2 + 2xy + 2y^2 - z = 0$ au point $(1, 1, 5)$.
2. $x^2 + y^2 - z = 0$ au point $(1, 2, 5)$.
3. $(y - x^2)(y - 2x^2) - z = 0$ au point $(1, 3, 2)$.

3.2 Différentielles d'ordre 2

Voyons les définitions des différentielles d'ordre 2 sur $\mathbb{R}^n$.

Différentiabilité ordre 2 : si f fonction deux fois différentiable de $\mathbb{R}^n$ dans $\mathbb{R}$

a) Hessien

Le **Hessien** $H_f(\mathbf{x})$ de f en $\mathbf{x}$ est une fonction de $\mathbb{R}^n \rightarrow \mathbb{R}^{n \times n}$ définie par :

$$H_f(x) = \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_n^2 \partial x_n} \end{pmatrix}$$

Notes :

- d'après le théorème de Schwarz, si f est deux fois dérivable en un point, alors son Hessien est symétrique en ce point.
- les propriétés du hessiens permettent de connaître la convexité de la surface au point où il est calculé.

EXERCICE 6: Hessien

Calculer le Hessien des fonctions suivantes :

1. $Q(x, y, z) = x^2 + 5y^2 + 4xy - 2yz$.
2. $f(x, y) = 3x^2y + 4x^3y^4 - 7x^9y^4$.

b) Courbure

Soit la fonction φ de variable s défini au point $\mathbf{x}$ dans une direction $\mathbf{d} \in \mathbb{R}^n$:

$$\varphi(s) = f(x + s\mathbf{d})$$

Elle représente la variation de f en x dans la direction $\mathbf{d}$.

On définit alors :

- sa dérivée première : $\varphi'(s) = d^T \nabla f(x + sd)$
 $\Rightarrow \varphi'(0) = d^T \nabla f(x)$
- sa dérivée seconde : $\varphi''(s) = d^T \nabla^2 f(x + sd) d$
 $\Rightarrow \varphi''(0) = d^T \nabla^2 f(x) d$

La courbure $C_f^d(x)$ de f en x dans la direction d est définie par :

$$C_f^d(x) = \frac{d^T \nabla^2 f(x) d}{d^T d}$$

c' est la normalisation de φ'' en $s = 0$.

= quotient de Rayleigh de $H_f(x)$ dans la direction d .

3.3 Jacobien

a) Définition

Soit c_i une fonction continue de $\mathbb{R}^n$ dans $\mathbb{R}$.

Soit $c = (c_1, \dots, c_m)$ la fonction construite comme le vecteur contenant l'ensemble des m fonctions de contraintes c_i , chacune de $\mathbb{R}^n$ dans $\mathbb{R}$.

Noter que la fonction c est de $\mathbb{R}^n$ dans $\mathbb{R}^m$.

Matrice gradient

Gradient de c en x : $\nabla c(x) : \mathbb{R}^n \rightarrow \mathbb{R}^{n \times m}$

$$\nabla c(x) = (\nabla c_1(x), \dots, \nabla c_m(x)) = \left(\frac{\partial c_j(x)}{\partial x_i} \right)_{\substack{i=1 \dots n \\ j=1 \dots m}} = \begin{pmatrix} \frac{\partial c_1(x)}{\partial x_1} & \dots & \frac{\partial c_m(x)}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial c_1(x)}{\partial x_n} & \dots & \frac{\partial c_m(x)}{\partial x_n} \end{pmatrix}$$

Matrice jacobienne

$$J_c(x) = \nabla c(x)^T = \begin{pmatrix} \nabla c_1(x)^T \\ \vdots \\ \nabla c_m(x)^T \end{pmatrix} = \left(\frac{\partial c_i(x)}{\partial x_j} \right)_{\substack{i=1 \dots m \\ j=1 \dots n}} = \begin{pmatrix} \frac{\partial c_1(x)}{\partial x_1} & \dots & \frac{\partial c_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial c_m(x)}{\partial x_1} & \dots & \frac{\partial c_m(x)}{\partial x_n} \end{pmatrix}$$

On appelle **jacobien** le déterminant de la matrice jacobienne.

b) Exemple d'utilisation

Dans un problème d'optimisation (PO), on construit la matrice jacobienne regroupant les contraintes égalité c_E et les contraintes inégalité c_I :

$$J : \mathbb{R}^n \rightarrow \mathbb{R}^{(p+q) \times n}$$

$$x \mapsto \begin{pmatrix} J_E(x) \\ J_I(x) \end{pmatrix} = \begin{pmatrix} \nabla c_E(x)^T \\ \nabla c_I(x)^T \end{pmatrix}$$

où p est le nombre de contraintes d'égalité et q le nombre de contraintes d'inégalité.

Notes :

- dans un PO, les fonctions c_i utilisés sont les contraintes du problème.
- la matrice gradient/jacobienne stocke l'ensemble des différentielles des $m = p + q$ contraintes $\{c_i\}_{i=1\dots m}$.
- noter que si c est une fonction unique ($m = 1$), le Jacobien est la transposée du gradient.

EXERCICE 7: Jacobienne

Donner la matrice Jacobienne pour les fonctions F suivantes :

1. $F(x, y, z) = (xyz, x^2z)$
2. $F(x, y) = (e^{xy}, \ln x)$
3. $F(x, y, z) = (\sin(xyz), xz)$

3.4 Lignes de niveau**a) Définition**

Les lignes de niveau sont un moyen pratique pour représenter les "reliefs" d'une fonction (cf carte IGN).


Définition

- **Ligne (ou surface) de niveau l_0 de la fonction f**
 $L_0 = \{x \in \mathbb{R}^n \mid f(x) = l_0\}$
 $\Rightarrow$ hypersurface dans $\mathbb{R}^n$ (sous-espace de dimension $n - 1$)
- **Ligne de niveau passant par x_0**
 $L_0 = \{x \in \mathbb{R}^n \mid f(x) = f(x_0)\}$
avec $f(x) = f(x_0) + \nabla f(x_0)^T(x - x_0) + o(\|x - x_0\|)$ à l'ordre 1

Gradient

$$x \in L_0 \Rightarrow f(x) = f(x_0) \Rightarrow \nabla f(x_0)^T(x - x_0) = 0 \Rightarrow \text{hyperplan tangent à } L_0 \text{ en } x_0$$

Le gradient de f est orthogonal aux lignes de niveaux.



b) Exemples

Ligne de niveau d'une fonction quadratique

$$f(x_1, x_2) = x_1^2 + 25x_2^2 = \frac{x_1^2}{1^2} + \frac{x_2^2}{(1/5)^2}$$

Courbes de niveau pour $f(x_1, x_2) = 1 : \Rightarrow \frac{x_1^2}{1^2} + \frac{x_2^2}{(1/5)^2} = 1$


ellipse de centre $(0, 0)$, grand axe = 1 sur x_1 , petit axe = $1/5$ sur x_2 .

Courbes de niveau pour $f(x_1, x_2) = 1/4 = 1/2^2 : \Rightarrow \frac{x_1^2}{(1/2)^2} + \frac{x_2^2}{(1/10)^2} = 1$


ellipse de centre $(0, 0)$, grand axe = $1/2$ sur x_1 , petit axe = $1/10$ sur x_2 .

Courbes de niveau pour $f(x_1, x_2) = 0 :$

comme $f > 0$ si $x_1 > 0$ et $x_2 > 0$, $f(x_1, x_2) = 0 \Rightarrow (x_1, x_2) = (0, 0)$.

**Ligne de niveau de la fonction de Rosenbrock**

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$



c) Exercices

EXERCICE 8: Courbes de niveau

les fonctions $f(x, y)$ suivantes pour les valeurs c indiquée, tracer les courbes de niveau $f(x, y) = c$.

1. $f(x, y) = xy$ pour $c = +1, -1, +3$.
2. $f(x, y) = e^{xy}$ pour $c = +1, -1, +3$.
3. $f(x, y) \ln(xy)$ pour $c = 0, +1, -1$.
4. $f(x, y) = (x + y)/(x - y)$ pour $c = 0, +2, -2$.
5. $f(x, y) = x^2 - y$ pour $c = 0, +1, -1$.
6. $f(x, y) = ye^x$ pour $c = 0, +1, -1$.

4 Approximation de Taylor

4.1 Principe

Pour une fonction réelle $f(x)$ (i.e. $f : \mathbb{R} \rightarrow \mathbb{R}$), la formule de Taylor fournit une approximation polynomiale de cette fonction en un point x_0 donné.


Plus l'ordre est élevé, plus l'approximation est proche de la fonction.

Avec un nombre infini de terme, **l'approximation est exacte**.

Exemple :

L'approximation de Taylor de $\sin(x)$ en $x_0 = 0$ est :

$$\sin(x) = x - \frac{1}{3!}x^3 + \frac{1}{5!}x^5 - \frac{1}{7!}x^7 + \frac{1}{9!}x^9 - \frac{1}{11!}x^{11} + \frac{1}{13!}x^{13} + o(h^{15})$$



4.2 Expression pour une fonction de $\mathbb{R} \rightarrow \mathbb{R}$

a) Définition

Pour une fonction réelle, la formule de Taylor au voisinage de x_0 s'écrit (où h représente l'écart à x_0) :

$$f(x_0 + h) = \sum_{k=0}^n \frac{f^{(k)}(x_0)}{k!} h^k + R_n(h)$$

où $\exists \epsilon \in [0, 1]$, tel que :

$$R_n(h) = \frac{f^{(n+1)}(x_0 + h\epsilon)}{(n+1)!} h^{n+1} = o(h^n)$$

L'ordre d'une formule de Taylor est la valeur de n jusqu'à laquelle le développement est calculé.

- **ordre 1** : approximation linéaire
- **ordre 2** : approximation quadratique

L'approximation de Taylor peut s'exprimer sous deux formes différentes :

- en fonction de $x - x_0$:
ordre 1 : $\tilde{f}(x) = f(x_0) + (x - x_0)f'(x_0) + o(|x - x_0|)$
ordre 2 : $\tilde{f}(x) = f(x_0) + (x - x_0)f'(x_0) + \frac{1}{2}(x - x_0)^2 f''(x_0) + o((x - x_0)^2)$
- en fonction de l'écart h à x_0 (idem avec le changement de variable $h = x - x_0$) :
ordre 1 : $\tilde{f}(x_0 + h) = f(x_0) + hf'(x_0) + o(h)$
ordre 2 : $\tilde{f}(x_0 + h) = f(x_0) + hf'(x_0) + \frac{1}{2}h^2 f''(x_0) + o(h^2)$

b) Exemple

Soit la fonction : $f(x) = -x^4 + 12x^3 - 47x^2 + 60x$

Calculons :

- le gradient : $\nabla f(x) = -4x^3 + 36x^2 - 94x + 60$
- le hessien : $\nabla^2 f(x) = -12x^2 + 72x - 94$

Regardons :

- Modèle quadratique en $x_0 = 3$:
 $f(3) = 0, \quad \nabla f(3) = -6, \quad \nabla^2 f(3) = 14$
 $f_0(x) = 0 - 6(x - 3) + \frac{1}{2} \cdot 14(x - 3)^2$
 $= 7x^2 - 48x + 81$
- Modèle quadratique en $x_0 = 4$:
 $f(4) = 0, \quad \nabla f(4) = 4, \quad \nabla^2 f(4) = 2$
 $f_0(x) = 0 + 4(x - 4) + \frac{1}{2} \cdot 2(x - 4)^2$
 $= x^2 - 4x$
- Modèle quadratique en $x_0 = 5$:
 $f(5) = 0, \quad \nabla f(5) = -10, \quad \nabla^2 f(5) = -34$
 $f_0(x) = 0 - 10(x - 5) + \frac{1}{2} \cdot (-34)(x - 5)^2$
 $= -17x^2 + 160x - 375$

4.3 Expression pour une fonction de $\mathbb{R}^n \rightarrow \mathbb{R}$

a) Définition

Voyons maintenant le cas dans $\mathbb{R}^n$. Soit :

- f fonction de $\mathbb{R}^n$ dans $\mathbb{R}$.
- x (variable), x_0 (point d'approximation) et h (écart à x_0) sont des vecteurs colonnes de $\mathbb{R}^n$.

L'approximation s'écrit dans $\mathbb{R}^n$ de la manière suivante :

- en fonction de $x - x_0$:
ordre 1 : $\tilde{f}(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + o(\|x - x_0\|)$
ordre 2 : $\tilde{f}(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 f(x_0) (x - x_0) + o(\|x - x_0\|^2)$

- en fonction de l'écart h à x_0 (idem avec le changement de variable $h = x - x_0$) :

ordre 1 : $\tilde{f}(x_0 + h) = f(x_0) + \nabla f(x_0)^T h + o(h)$

ordre 2 : $\tilde{f}(x_0 + h) = f(x_0) + \nabla f(x_0)^T h + \frac{1}{2} h^T \nabla^2 f(x_0) h + o(h^2)$

Remarquez que :

- $\nabla f(x_0)$ est un vecteur colonne de dimension n . Ainsi, $\nabla f(x_0)^T h$ est le produit scalaire entre $\nabla f(x_0)$ et h , donc un scalaire.
- $\nabla^2 f(x_0)$ est une matrice de taille $n \times n$, donc $\nabla^2 f(x_0) h$ est un vecteur colonne, et ainsi $h^T \nabla^2 f(x_0) h$ est un scalaire.

Dans $\mathbb{R}^n$, le théorème de Taylor s'exprime sous la forme suivante :

- **ordre 1 :** $\tilde{f}(x)$ approxime f en x par un hyperplan.
- **ordre 2 :** $\tilde{f}(x)$ approxime f en x par une hypersurface quadratique.

b) Exemple

Soit la fonction : $f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$

Calculons :

- le gradient : $\nabla f(x) = \begin{pmatrix} -400(x_2 - x_1^2)x_1 - 2(1 - x_1) \\ 200(x_2 - x_1^2) \end{pmatrix}$
- le hessien : $\nabla^2 f(x) = \begin{pmatrix} -400(x_2 - 3x_1^2) + 2 & -400x_1 \\ -400x_1 & 200 \end{pmatrix}$

Regardons le modèle quadratique en $x_0 = (1, 1)$

$$f(x_0) = 0, \quad \nabla f(x_0) = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad \nabla^2 f(x_0) = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix}$$

$$\begin{aligned} f_0(x_1, x_2) &= 0 + \begin{pmatrix} 0 \\ 0 \end{pmatrix}^T \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} + \frac{1}{2} \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix}^T \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix} \begin{pmatrix} x_1 - 1 \\ x_2 - 1 \end{pmatrix} \\ &= 401(x_1 - 1)^2 - 400(x_1 - 1)(x_2 - 1) + 100(x_2 - 1)^2 \end{aligned}$$

c) Exercice

EXERCICE 9: Développement de Taylor

Calculer le développement de Taylor à l'ordre 2 des fonctions suivante au point indiqué :

1. $f(x, y) = \ln(1 + x + 2y)$ au point $(2, 1)$.
2. $f(x, y) = x^3 + 3x^2y + 6xy^2 - 5x^2 + 3xy^2$ au point $(1, 2)$.
3. $f(x, y) = e^{x+y}$ au point $(0, 0)$.
4. $f(x, y) = \sin(xy) + \cos(xy)$ au point $(0, 0)$.
5. $f(x, y, z) = x - y^2 + xz$ au point $(1, 0, 3)$.

4.4 Application à l'optimisation

Considérons le problème d'optimisation suivant avec contraintes égalité :

$$\min_{x \in \mathbb{R}^n} f(x) \text{ sous la contrainte } c(x) = 0$$

Fonction modèle : application du théorème de Taylor au point $x_0 \in \mathbb{R}^n$

- Modèle quadratique du critère :

$$\tilde{f}_0(x) = f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0)$$
- Modèle linéaire des contraintes :

$$\tilde{c}_0(x) = c(x_0) + \nabla c(x_0)^T (x - x_0)$$

Problème quadratique-linéaire local

Au voisinage de x_0 :

- $f(x) \approx \tilde{f}_0(x)$,
- $c(x) \approx \tilde{c}_0(x)$.

Le problème d'optimisation peut être approximé en x_0 par :

$$\min_{x \in \mathbb{R}^n} \tilde{f}_0(x) \text{ sous } \tilde{c}_0(x) = 0$$

⇒ Problème quadratique-linéaire d'optimisation :

- localement « proche » du problème initial
- plus simple à résoudre

5 Dérivées numériques

5.1 Différences finies

Différences finies

Les expressions analytiques de $\nabla f(x)$ et $\nabla^2 f(x)$ ne sont généralement pas disponibles.

⇒ Evaluation par différences finies avec incrément h appliqué successivement sur chaque variable.

$$x \rightarrow x + he_i \text{ avec } e_i = (0, \dots, \overset{1}{0}, \dots, \overset{i-1}{0}, \overset{i}{1}, \overset{i+1}{0}, \dots, \overset{n}{0})^T, i = 1 \text{ à } n.$$

Gradient

- Différence finie simple :

$$\frac{\partial f}{\partial x_i}(x) = \frac{f(x + he_i) - f(x)}{h} + o(h)$$

amont si $h < 0$, aval si $h > 0$ ⇒ n appels fonction pour évaluer $\nabla f(x)$

- Différence finie centrée :

$$\frac{\partial f}{\partial x_i}(x) = \frac{f(x + he_i) - f(x - he_i)}{2h} + o(h^2)$$

plus précis ⇒ $2n$ appels fonction pour évaluer $\nabla f(x)$

Hessien

Différence finie simple :

$$\frac{\partial^2 f}{\partial x_i \partial x_j}(x) = \frac{f(x + he_i + he_j) - f(x + he_i) - f(x + he_j) + f(x)}{h^2} + o(h)$$

$$\frac{\partial^2 f}{\partial x_i^2}(x) = \frac{f(x + 2he_i) - 2f(x + he_i) + f(x)}{h^2} + o(h) \quad (\text{sur la diagonale})$$

⇒ $n(n+1)/2 + n$ appels fonction pour évaluer $\nabla^2 f(x)$

EXERCICE 10: Différences finies

Une fonctionnelle f est "mesurée" pour les valeurs suivantes.

n	1	2	3	4	5	6
x_n	0.50	0.60	0.70	0.80	0.90	1.00
$f(x_n)$	0.125	0.216	0.343	0.512	0.729	1.000

n	7	8	9	10	11
x_n	1.10	1.20	1.30	1.40	1.50
$f(x_n)$	1.331	1.728	2.197	2.744	3.375

1. calculer le pas h .
2. calculer le gradient en x_6 avec la méthode des différences finies simples.
3. calculer le gradient en x_6 avec la méthode des différences finies centrées.
4. calculer le Hessien en x_6 avec la méthode des différences finies simples.
5. la fonctionnelle f est en fait la fonction $f(x) = x^3$. Calculer les erreurs d'approximation.

EXERCICE 11: Différences finies

On dispose de l'estimation suivante des valeurs d'une fonctionnelle $f(x, y)$ sur une grille.

0.512	0.648	0.800	0.968	1.152
0.576	0.729	0.900	1.089	1.296
0.640	0.810	1.000	1.210	1.440
0.704	0.891	1.100	1.331	1.584
0.768	0.972	1.200	1.452	1.728

On effectuera toutes les estimations au centre de la grille (*i.e.* au point où $f(x, y) = 1$), et on supposera que $h = 0.1$.

1. Calculer le gradient au centre de la grille par la méthode des différences finies.
2. Calculer la dérivée directionnelle dans la direction $d = (1, 1)$.
3. Calculer le Hessien.
4. Donner la formule de Taylor d'ordre 1 de f , et l'utiliser avec $\mathbf{h}' = [0.1 \ 0.1]^T$.
5. Donner la formule de Taylor d'ordre 2 de f , et l'utiliser avec $\mathbf{h}' = [0.1 \ 0.1]^T$.

5.2 Erreurs numériques**a) Analyse**

Sources d'erreurs : L'évaluation d'une dérivée par différence finie génère 2 types d'erreurs :

- Erreur d'arrondi (ou de conditionnement)
- Erreur de troncature

Erreur d'arrondi

Les réels sont représentés en mémoire machine avec une précision finie.

La précision machine ε_m est le plus petit réel tel que : $1 + \varepsilon_m \neq 1$

$\Rightarrow$ erreur relative $\varepsilon_m \approx 10^{-16}$ sur la valeur d'un réel x en double précision

$\Rightarrow$ erreur relative ε_r sur la valeur évaluée de $f(x)$

$\varepsilon_r \gg \varepsilon_m$ par cumul des erreurs au cours des opérations pour passer de x à $f(x)$

$f_{\text{eval}}(x) = f_{\text{exact}}(x)(1 \pm \varepsilon_r) = f_{\text{exact}}(x) \pm \varepsilon_f \Rightarrow \varepsilon_f = \text{erreur absolue sur } f.$

Erreur de troncature

L'évaluation d'une dérivée par différence finie tronque le développement de Taylor à l'ordre 1.

- $f(x_0 + h) = f(x_0) + hf'(x_0) + \frac{1}{2}h^2 f''(x_0 + sh)$ avec $s \in [0, 1]$.

- $f(x_0 + h) = f(x_0) + hf'(x_0) \pm \frac{1}{2}h^2 \varepsilon_t$ avec $\varepsilon_t < M$

où M est le majorant de $|f''(x)|$ sur $[x_0, x_0 + d]$.

Evaluons l'erreur sur une dérivée numérique

$$f'_{\text{eval}}(x_0) = \frac{f_{\text{eval}}(x_0 + h) - f_{\text{eval}}(x_0)}{h}$$

Évaluons chacun des termes :

$$f_{\text{eval}}(x_0) = f_{\text{exact}}(x_0) \pm \varepsilon_f \Rightarrow \text{arrondi sur } f_{\text{eval}}(x_0)$$

$$f_{\text{eval}}(x_0 + h) = f_{\text{exact}}(x_0 + h) \pm \varepsilon_f \Rightarrow \text{arrondi sur } f_{\text{eval}}(x_0 + h)$$

Exprimons $f_{\text{exact}}(x_0 + h)$ en fonction de son évaluation en x_0 :

$$f_{\text{exact}}(x_0 + h) = f_{\text{exact}}(x_0) + hf'_{\text{exact}}(x_0) \pm \frac{1}{2}h^2 \varepsilon_t \Rightarrow \text{troncature sur } f_{\text{exact}}(x_0 + h)$$

En remplaçant dans l'expression de $f'_{\text{eval}}(x_0)$:

$$\begin{aligned} f'_{\text{eval}}(x_0) &= \frac{f_{\text{exact}}(x_0 + h) - f_{\text{exact}}(x_0) \pm 2\varepsilon_f}{h} = \frac{hf'_{\text{exact}}(x_0) \pm \frac{1}{2}h^2 \varepsilon_t \pm 2\varepsilon_f}{h} \\ &= f'_{\text{exact}}(x_0) \pm \frac{h\varepsilon_t}{2} \pm \frac{2\varepsilon_f}{h} \end{aligned}$$

L'erreur maximale sur la dérivée numérique est : $\varepsilon_{f'} = \frac{h\varepsilon_t}{2} + \frac{2\varepsilon_f}{h}$


b) Incrément optimal

- On veut choisir l'incrément h d'une dérivée numérique pour minimiser l'erreur $\varepsilon_{f'}$:

$$\begin{aligned} \min_h \varepsilon_{f'} &= \min_h \frac{h\varepsilon_t}{2} + \frac{2\varepsilon_f}{h} \\ \text{Il faut : } \frac{d\varepsilon_{f'}}{dh} &= \frac{\varepsilon_t}{2} - \frac{2\varepsilon_f}{h^2} = 0 \\ \Rightarrow h^* &= 2\sqrt{\frac{\varepsilon_f}{\varepsilon_t}} \end{aligned}$$

En effet,

$$\begin{aligned} \min_{h=h^*} \varepsilon_{f'} &= 2\sqrt{\frac{\varepsilon_f}{\varepsilon_t}} \frac{\varepsilon_t}{2} + 2\varepsilon_f \frac{1}{2} \sqrt{\frac{\varepsilon_t}{\varepsilon_f}} \\ &= 2\sqrt{\varepsilon_t \varepsilon_f} \end{aligned}$$



si h est trop grand, $o(h)$ n'est pas négligeable.

si h est trop petit, les erreurs numériques dominent $o(h)$.

• Règle empirique de réglage de l'incrément

En supposant que l'ordre de grandeur de la dérivée seconde est de l'ordre de 1 :

$$h_{opt} \approx \sqrt{\varepsilon_f} \quad \text{incrément de l'ordre de la racine de la précision d'évaluation de } f.$$

$$\varepsilon_{f'} \approx \sqrt{\varepsilon_f} \quad \text{précision sur } f' \text{ de l'ordre de la racine de la précision d'évaluation de } f \text{ (2 fois moins de chiffres significatifs).}$$

à savoir, à une constante proportionnelle près.


c) Exemple sur une dérivée numérique

$$\text{Soit } f(x) = x^4 + x^2 \rightarrow f'(x) = 4x^3 + 2x$$

- Dérivée en $x = 1$: $f'(1) = 6$

- Dérivée numérique avec incrément $h \Rightarrow$ erreur $e(h) = \left| \frac{f(x+h) - f(x)}{h} - f'(x) \right|$

h	$\frac{f(x+h) - f(x)}{h}$	Erreur
1E-01	6,7410000000	7,410E-01
1E-02	6,0704010000	7,040E-02
1E-03	6,0070040010	7,004E-03
1E-04	6,0007000400	7,000E-04
1E-05	6,0000700004	7,000E-05
1E-06	6,0000069997	7,000E-06
1E-07	6,0000007007	7,007E-07
1E-08	6,0000000079	7,944E-09
1E-09	6,0000004964	4,964E-07
1E-10	6,0000004964	4,964E-07
1E-11	6,0000004964	4,964E-07
1E-12	6,0005334035	5,334E-04
1E-13	5,9952043330	-4,796E-03
1E-14	5,9952043330	-4,796E-03
1E-15	6,6613381478	6,613E-01



incrément adapté

L'incrément optimal se situe autour de 10^{-8} (meilleur compromis troncature / arrondi).

d) Exercice

EXERCICE 12: Différences finies

On considère la fonction $f(x) = x^3$.

1. Calculer $f'(x)$, et $f'(1)$.
2. Calculer $f(1+h)$. On développera.
3. Comment aurait-on pu obtenir autrement l'expression de la question précédente ?
4. Donner l'expression de $f'(1)$ par différence finie.
5. On veut estimer $f'(1)$ par différence finie. On utilise un pas $h_n = 10^{-n}$, et on mesure l'erreur d'approximation avec $\varepsilon_n(x) = \frac{f(x+h_n) - f(x)}{h_n} - f'(x)$.

h_n	$\varepsilon_n(x)$	h_n	$\varepsilon_n(x)$	h_n	$\varepsilon_n(x)$	h_n	$\varepsilon_n(x)$
1	6.410e-01	5	6.000043e-05	9	3.309615e-07	13	-3.197111e-03
2	6.040100e-02	6	5.999760e-06	10	3.309615e-07	14	-3.197111e-03
3	6.004001e-03	7	6.018559e-07	11	3.309615e-07	15	4.408921e-01
4	6.000400e-04	8	4.230350e-08	12	3.556023e-04	16	-4.000000e+00

Expliquer le comportement de $\varepsilon_n(x)$ sachant que $\varepsilon = 10^{-16}$ sur la machine considérée.

5.3 Dérivée complexe

a) Principe

On peut améliorer la précision sur la dérivée par différence finie en nombres complexes.

- Développement de f en x_0 :

$$f(x_0 + h) = f(x_0) + hf'(x_0) + \frac{h^2}{2}f''(x_0) + \frac{h^3}{6}f'''(x_0) + o(h^3)$$

- Estimation de la dérivée avec un incrément réel h

$$\frac{f(x_0 + h) - f(x_0)}{h} = f'(x_0) + \frac{h}{2}f''(x_0) + \frac{h^2}{6}f'''(x_0) + o(h^2)$$

$\Rightarrow$ précision de l'ordre de h

L'incrément h ne peut pas être choisi trop petit à cause de l'erreur d'arrondi.

$$\Rightarrow h \approx \sqrt{\varepsilon_f}$$

- Estimation de la dérivée avec un incrément imaginaire ih

$$\frac{f(x_0 + ih) - f(x_0)}{h} = if'(x_0) - \frac{h}{2}f''(x_0) - i\frac{h^2}{6}f'''(x_0) + o(h^2)$$

$$\Rightarrow \operatorname{Im} \frac{f(x_0 + ih) - f(x_0)}{h} = f'(x_0) - \frac{h^2}{6}f'''(x_0) + o(h^2)$$

$\Rightarrow$ précision de l'ordre de h^2 .

L'incrément h peut être choisi à la précision machine car il ne porte que sur la partie imaginaire de f .

$$\Rightarrow h \approx \varepsilon_f$$

b) Application

- La dérivée numérique est évaluée par différence finie complexe.

$$f'(x_0) \approx \operatorname{Im} \frac{f(x_0 + ih) - f(x_0)}{h}$$

- Il faut que l'ensemble du logiciel soit écrit en variables complexes pour propager l'incrément imaginaire ih de $x_0 + ih$ à $f(x_0 + ih)$.

$\Rightarrow$ Programmation directe en déclarant des variables complexes

ou

$\Rightarrow$ Surcharge d'opérateurs pour effectuer toutes les opérations en complexes

c) Application

Soit $f(x) = x^2 \Rightarrow f'(x) = 2x$

- Différence finie réelle : $\frac{f(x_0 + h) - f(x_0)}{h} = \frac{(x_0 + h)^2 - (x_0)^2}{h} = 2x_0 + h$

$\Rightarrow$ erreur = h

- Différence finie imaginaire : $\frac{f(x_0 + ih) - f(x_0)}{h} = \frac{(x_0 + ih)^2 - (x_0)^2}{h} = 2ix_0 - h^2$

$$\Rightarrow \operatorname{Im} \left(\frac{f(x_0 + ih) - f(x_0)}{h} \right) = 2x_0 \Rightarrow \text{valeur exacte}$$

6 Matrice

6.1 Valeurs et vecteurs propres

Une matrice $A \in \mathbb{R}^{n \times n}$ admet la valeur propre $\sigma \in \mathbb{R}$
s'il existe un vecteur non nul $v \in \mathbb{R}^n$ tel que : $Av = \sigma v$
 v est un vecteur propre associé à la valeur propre σ .

Interprétation : pour une valeur propre λ_i non nulle, son vecteur propre v_i associé est une direction particulière dans laquelle les vecteurs sont étirés d'un facteur λ_i .

Note : une matrice de taille $n \times n$ a n valeurs propres, éventuellement dans $\mathbb{C}$.

6.2 Matrices particulières

- A non singulière $\Leftrightarrow$ Aucune valeur propre de A n'est nulle.
- A symétrique $\Leftrightarrow A^T = A$
 $\Rightarrow A$ admet n valeurs propres réelles (distinctes ou non)
 $\Rightarrow A$ admet une base orthonormée de vecteurs propres
- A orthogonale $\Leftrightarrow AA^T = A^T A = I$
- A semi-définie positive $\Leftrightarrow v^T A v \geq 0$ pour tout $v \in \mathbb{R}^n$
- A définie positive $\Leftrightarrow v^T A v > 0$ pour tout $v \in \mathbb{R}^n$
- A symétrique définie positive $\Rightarrow A$ admet n valeurs propres réelles positives (distinctes ou non), et ses vecteurs propres forment une base orthonormée.

6.3 Noyau, image et rang

a) Définitions

Pour une matrice A de $\mathbb{R}^{n \times m}$ (n lignes, m colonnes)

- Le noyau de A (noté $\ker(A)$) est constitué de l'ensemble des vecteurs tels que $Ax = 0$ (à savoir $\ker(A) = \{x \mid Ax = 0\}$). On l'appelle aussi espace nul.
 Une base de $\ker(A)$ s'appelle aussi base de l'espace nul.
- Le rang de A est le nombre maximal de lignes ou de colonnes indépendantes de A . On le note $\text{rang}(A)$.
- **Propriété :** $\text{rang}(A) = n - \dim \ker(A)$
- L'image de A (noté $\text{Im}(A)$) est l'ensemble des points que A peut construire (à savoir $\text{Im}(A) = \{Ax \mid x \in \mathbb{R}^n\}$).
- **Propriété :** $n = \dim \ker(A) + \dim \text{Im}(A)$
 autrement dit, $\text{rang}(A) = \dim \text{Im}(A)$.

b) Exemple

Un problème d'optimisation s'écrit sous forme canonique :

$$\min_{x \in \mathbb{R}^n} f(x) \text{ sous } \begin{cases} c_E(x) = 0 \\ c_I(x) \leq 0 \end{cases}$$

où $c_E(x) = 0$ et $c_I(x) \leq 0$ sont respectivement les p contraintes d'égalités et les q contraintes d'inégalités.

Par souci d'exposition ici, et pour des raisons qui apparaîtront par la suite, supposons que toutes ces contraintes sont :

- des contraintes d'égalité (on note $m = p + q$),
- linéaires, à savoir qu'elles sont sous la forme $a_1x_1 + \dots + a_nx_n + c = 0$.

La $j^{\text{ème}}$ contrainte s'écrit : $c_j(x) = a_{j,1}x_1 + a_{j,2}x_2 + \dots + a_{j,n}x_n + b_j = 0$

Le système (S_c) des contraintes s'écrit donc sous la forme :

$$(S_c) \quad \begin{cases} a_{1,1}x_1 + a_{1,2}x_2 + \dots + a_{1,n}x_n + b_1 = 0 & (c_1) \\ a_{2,1}x_1 + a_{2,2}x_2 + \dots + a_{2,n}x_n + b_2 = 0 & (c_2) \\ \vdots & \vdots \\ a_{m,1}x_1 + a_{m,2}x_2 + \dots + a_{m,n}x_n + b_m = 0 & (c_m) \end{cases}$$

Comment déterminer si combien de contraintes ce système représentent effectivement ?

Notamment, il peut y avoir des dépendances :

- directe : $c_i(x) = 3c_j(x)$
- ou toute dépendance linéaire : $2c_i(x) - 4c_j(x) = -c_k(x)$

Ce problème est traité en calculant la matrice Jacobienne du système S_c :

$$J_c(x) = \nabla c(x)^T = \begin{pmatrix} \nabla c_1(x)^T \\ \vdots \\ \nabla c_m(x)^T \end{pmatrix} = \begin{pmatrix} \frac{\partial c_1(x)}{\partial x_1} & \dots & \frac{\partial c_1(x)}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial c_m(x)}{\partial x_1} & \dots & \frac{\partial c_m(x)}{\partial x_n} \end{pmatrix} = \begin{pmatrix} a_{1,1} & a_{1,2} & \dots & a_{1,n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m,1} & a_{m,2} & \dots & a_{m,n} \end{pmatrix}$$

Dans le cas d'une matrice Jacobienne :

- Le rang de $J_c(x)$ est le nombre de contraintes indépendantes.
- Le noyau dit comment on peut bouger sans changer la contrainte.
- L'image donne quelles sont les corrections de contraintes possibles.

On peut ainsi déterminer les dépendances entre les différentes variables du problème.

6.4 Factorisation

3 types de factorisations sont utiles dans les algorithmes d'optimisation.

- **Factorisation LU :**

Pour réduire le problème (*variables* dépendantes et indépendantes)
 Pour construire une base de l'espace nul
 Méthode du pivot de Gauss

- **Factorisation QR :**

Pour réduire le problème (variables dépendantes et indépendantes)
 Pour construire une base orthogonale de l'espace nul
 Méthode de Householder ou de Givens

- **Factorisation LL^T ou LDL^T**

Pour vérifier qu'une matrice est définie positive
 Pour rendre le hessien défini positif.
 La factorisation LL^T est dite de Cholesky.

Ces méthodes ne sont pas décrites dans ce cours.

Voir le cours de Max Cerf ou les "Numerical Recipes".

6.5 Permutation

Nous donnons ici la matrice E qui permet de permuter les colonnes d'une autre matrice.

$A \in \mathbb{R}^{m \times n}$, matrice à m lignes, n colonnes

$E \in \mathbb{R}^{n \times n}$, matrice de permutation des colonnes j et k

$$E^T = E$$

$$E = \begin{matrix} & \begin{matrix} 1 & \dots & j & \dots & k & \dots & n \end{matrix} \\ \begin{matrix} 1 \\ \vdots \\ j \\ \vdots \\ k \\ \vdots \\ n \end{matrix} & \begin{pmatrix} 1 & \dots & 0 & \dots & 0 & \dots & 0 \\ \vdots & \ddots & \vdots & & \vdots & & \vdots \\ 0 & \dots & 0 & \dots & 1 & \dots & 0 \\ \vdots & & \vdots & \ddots & \vdots & & \vdots \\ 0 & \dots & 1 & \dots & 0 & \dots & 0 \\ \vdots & & \vdots & & \vdots & \ddots & \vdots \\ 0 & \dots & 0 & \dots & 0 & \dots & 1 \end{pmatrix} \end{matrix} \quad \longrightarrow \quad \begin{matrix} & \begin{matrix} 1 & \dots & j & \dots & k & \dots & n \end{matrix} \\ \begin{matrix} 1 \\ \vdots \\ m \end{matrix} & \begin{pmatrix} \times & \dots & \times & \dots & \times & \dots & \times \\ \vdots & & \vdots & & \vdots & & \vdots \\ \times & \dots & \times & \dots & \times & \dots & \times \end{pmatrix} \end{matrix}$$

$$AE = \begin{matrix} & \begin{matrix} 1 & \dots & j & \dots & k & \dots & n \end{matrix} \\ \begin{matrix} 1 \\ \vdots \\ m \end{matrix} & \begin{pmatrix} \times & \dots & \times & \dots & \times & \dots & \times \\ \vdots & & \vdots & & \vdots & & \vdots \\ \times & \dots & \times & \dots & \times & \dots & \times \end{pmatrix} \end{matrix}$$

Diagram illustrating the permutation of columns in matrix A using matrix E . Matrix E is a permutation matrix that swaps columns j and k . The resulting matrix AE shows the columns of A permuted accordingly. The columns of A are labeled 1, ..., j, ..., k, ..., n. The columns of AE are labeled 1, ..., j, ..., k, ..., n. The columns of A are permuted such that column j moves to column k and column k moves to column j .

Elle est par exemple utilisée dans le chapitre 3 de ce cours afin de réarranger les colonnes d'une matrice A dans le but de construire de n'avoir dans les premières colonnes que les celles qui sont indépendantes les uns des autres.

Note : Pour permuter les **colonnes**, multiplier à **gauche** par E . Pour permuter les **lignes**, multiplier à **droite** par E .

6.6 Système linéaire

a) Résolution d'un système linéaire

$$Ax = b \text{ avec } \begin{cases} A \in \mathbb{R}^{m \times n} & \text{matrice de rang } r : \text{rang}(A) = r \\ b \in \mathbb{R}^m & m \text{ équations} \\ x \in \mathbb{R}^n & n \text{ inconnues} \end{cases}$$

Le rang de A est la dimension du sous-espace engendré par A (image de A).

$$\text{Im}(A) = \{y = Ax, x \in \mathbb{R}^n\} \Rightarrow r = \dim(\text{Im}(A)) \leq m, n$$

Solutions possibles :

- **Pas de solution :** système incompatible ($m > n$: plus d'équations que d'inconnues)
- **Solution unique :** système non singulier ($m = n$: autant d'équations que d'inconnues)
- **Infinité de solutions :** système sous-déterminé ($m < n$: moins d'équations que d'inconnues)

Problème d'optimisation :

Contraintes linéaires $Ax = b \rightarrow$ **système sous-déterminé** ($m < n$)

$\Rightarrow$ $n-m$ inconnues «libres» permettant de minimiser le critère

b) Contraintes redondantes

Pour un système sous-déterminé ($m < n$), si A est de rang déficient :

$$\text{rang}(A) = r < m,$$


on peut extraire de A une sous-matrice $\tilde{A} \in \mathbb{R}^{r \times n}$ de rang plein, telle que :

$$\tilde{A}x = \tilde{b} \Leftrightarrow Ax = b$$

$\tilde{A}$ est composée des lignes $l_1, \dots, l_r$ de A .

Les lignes $l_{r+1}, \dots, l_m$ sont combinaisons linéaires des lignes $l_1, \dots, l_r$.

Elles correspondent à des contraintes redondantes et peuvent être éliminées de la résolution.




7 Convexité

7.1 Définitions


a) Ensemble convexe

$$X \subseteq \mathbb{R}^n \text{ convexe} \Leftrightarrow \forall x, y \in X, \forall \lambda \in [0, 1], \lambda x + (1 - \lambda)y \in X$$


Interprétation géométrique : tout segment totalement inclus dans X .



non connexe



non convexe




convexe

signifie aussi **qu'il n'y a pas de trou**.

Exemple :


- Ensemble : $X = \{(x_1, x_2) / x_1^2 + x_2^2 \leq 1\}$
 $\Rightarrow$ convexe
- Ensemble : $X = \{(x_1, x_2) / x_1^2 + x_2^2 \geq 1\}$
 $\Rightarrow$ non convexe



b) Fonction convexe

f fonction de $\mathbb{R}^n$ dans $\mathbb{R}$


$$\begin{aligned}
 f \text{ convexe} & \Leftrightarrow \forall x, y \in \mathbb{R}^n \\
 f \text{ strictement convexe} & \Leftrightarrow \forall \lambda \in [0, 1], f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) \\
 f \text{ concave} & \Leftrightarrow \forall x, y \in \mathbb{R}^n, \forall \lambda \in]0, 1[, f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y)
 \end{aligned}$$



Interprétation géométrique : Sécante au dessus de la courbe
Concavité vers le haut.

Exemple :

- Fonction : $f(x) = x^2$
 $f''(x) = 2 \Rightarrow$ convexe sur $\mathbb{R}$
- Fonction : $f(x) = x^3$
 $f''(x) = 6x \Rightarrow$ convexe sur $\mathbb{R}^+$
 $\Rightarrow$ non convexe sur $\mathbb{R}$




7.2 Lien avec les différentielles

a) Lien avec le gradient

f fonction différentiable de $X \subseteq \mathbb{R}^n$ dans $\mathbb{R}$, X ensemble convexe ouvert.

$$f \text{ convexe} \Leftrightarrow \forall x, y \in X, f(y) - f(x) \geq (y - x)^T g(x)$$

$$f \text{ strictement convexe} \Leftrightarrow \forall x, y \in X, f(y) - f(x) > (y - x)^T g(x)$$



Interprétation géométrique : Tangente au dessous de la courbe

b) Lien avec le Hessian

f fonction deux fois différentiable de $X \subseteq \mathbb{R}^n$ dans $\mathbb{R}$, X ensemble convexe ouvert

$$f \text{ convexe} \Leftrightarrow \forall x \in \mathbb{R}^n, H(x) \text{ semi-définie positive}$$

$$f \text{ strictement convexe} \Leftrightarrow \forall x \in \mathbb{R}^n, H(x) \text{ définie positive}$$

Rappel : matrice définie positive

$$A \in \mathbb{R}^{n \times n}$$

$$A \text{ définie positive} \Leftrightarrow \forall d \in \mathbb{R}^n, d^T A d > 0$$

$$A \text{ semi-définie positive} \Leftrightarrow \forall d \in \mathbb{R}^n, d^T A d \geq 0$$

7.3 Test de convexité

Soit $H_f(x)$ le Hessien de f en x .

Pour résumer :

- f est strictement concave en p ssi $H_f(p)$ définie négative,
- f est concave en p ssi $H_f(p)$ définie semi-définie négative,
- f est strictement convexe en p ssi $H_f(p)$ définie positive,
- f est convexe en p ssi $H_f(p)$ définie semi-définie positive.

f est concave (resp. convexe) sur un ensemble convexe D ssi $\forall x \in D$, $f(x)$ est concave (resp. convexe).

Quels sont les propriétés mathématiques qui peuvent être utilisés ?

- un Hessien est **symétrique**,
- une matrice est symétrique définie positive (resp. négative) a ses valeurs propres réelles positives (resp. négative).
- dans la base de ses vecteurs propres, une matrice est diagonale.

Regardons tout d'abord comment vérifier si une matrice est (semi-) définie-positive/négative dans le cas d'une matrice diagonale A .

$$\text{Soit } A = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \lambda_n \end{bmatrix}.$$

Sa forme quadratique associée est $Q(x) = xAx^t = \lambda_1 x_1^2 + \dots + \lambda_n x_n^2$.

En conséquence,

- A est définie positive ($\Leftrightarrow \forall x, Q(x) > 0$) ssi $\forall i, \lambda_i > 0$.
- A est semi-définie positive ($\Leftrightarrow \forall x, Q(x) \geq 0$) ssi $\forall i, \lambda_i \geq 0$.
- A est définie négative ($\Leftrightarrow \forall x, Q(x) < 0$) ssi $\forall i, \lambda_i < 0$.
- A est semi-définie négative ($\Leftrightarrow \forall x, Q(x) \leq 0$) ssi $\forall i, \lambda_i \leq 0$.
- indéfinie ssi $\lambda_i < 0$ ou $\lambda_i > 0$

Comment faire dans le cas général d'une matrice symétrique ?

$$\text{Soit une matrice symétrique } A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{12} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1n} & a_{2n} & \dots & a_{nn} \end{bmatrix}.$$

$$\text{Soit } D_1 = a_{11}, D_2 = \begin{vmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{vmatrix}, D_3 = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{12} & a_{22} & a_{23} \\ a_{13} & a_{23} & a_{33} \end{vmatrix}, \dots, D_n = |A|.$$

Alors, on peut montrer qu'il existe un changement de variables $Tx = z$ telle que la forme quadratique $Q(x) = xAx^t$ s'écrit :

$$Q(z) = D_1 z_1^2 + \frac{D_2}{D_1} z_2^2 + \frac{D_3}{D_2} z_3^2 + \dots + \frac{D_n}{D_{n-1}} z_n^2$$

En conséquence,

- A est définie positive ($\Leftrightarrow \forall z, Q(z) > 0$) ssi $\forall i, D_i > 0$

- A est semi-définie positive ($\Leftrightarrow \forall z, Q(z) \geq 0$) si $D_n = 0$ et $\forall i < n, D_i > 0$.
- A est définie négative ($\Leftrightarrow \forall z, Q(z) < 0$) ssi $\forall i, (-1)^i D_i > 0$
à savoir tous les rapport D_n/D_{n-1} sont négatifs.
- A est semi-définie négative ($\Leftrightarrow \forall z, Q(z) \leq 0$) si $D_n = 0$ et $\forall i, (-1)^i D_i > 0$

EXERCICE 13: Convexité

Déterminer les domaines du plan où les fonctions suivantes convexes ou concaves.

1. $f(x, y) = (x - 1)^2 + xy^2$.
2. $g(x, y) = \frac{x^3}{3} - 4xy + 12x + y^2$.
3. $h(x, y) = e^{-x} + e^{-y}$.
4. $k(x, y) = e^{xy}$.
5. $l(x, y) = \ln \sqrt{xy}$.

8 Conditionnement

8.1 Compléments sur la norme d'une matrice

- La norme induite sur les matrices carrées de taille $n \times n$ (= ensemble $\mathcal{M}_n(\mathbb{R})$) est définie par :

$$\|A\| = \sup \{\|Ax\|; x \in \mathbb{R}^n, \|x\| = 1\}, \forall A \in \mathcal{M}_n(\mathbb{R})$$

- cette norme vérifie les propriétés suivantes :
 - ◇ $\|Ax\| \leq \|A\| \|x\|, \forall x \in \mathbb{R}^n$
 - ◇ $\|A\| = \max \left\{ \frac{\|Ax\|}{\|x\|}; x \in \mathbb{R}^n \setminus \{0\} \right\}$
- si $A \in \mathcal{M}_n(\mathbb{R})$ est inversible, alors le rayon spectral est défini comme :

$$\rho(A) = \max \{|\lambda|; \lambda \in \mathbb{C}, \lambda \text{ valeur propre de } A\}, \quad \text{notée } \sigma_1$$

où σ_1 est la plus grande valeur propre de A .

- la norme $\|\cdot\|_2$ sur $\mathcal{M}_n(\mathbb{R})$ est définie par :

$$\|A\|_2 = (\rho(A^t A))^{\frac{1}{2}}$$

En particulier, si A est symétrique $\|A\|_2 = \rho(A) = \sigma_n$.

- $\rho((A^t A)^{-1}) = 1/\sigma_n$ où σ_n est la plus petite valeur propre de A .

8.2 Définition

On appelle conditionnement d'une matrice le scalaire permettant d'estimer l'erreur relative qui sera commise lorsque que l'on introduit des petites perturbations lors de l'inversion d'une matrice.

Conditionnement d'une matrice

A matrice symétrique semi-définie positive

Valeurs propres de A : $\sigma_1 \geq \dots \geq \sigma_n \rightarrow \|A\|_2 = \sigma_1$

Nombre de conditionnement de A : $\kappa(A) = \|A\|_2 \|A^{-1}\|_2 = \frac{\sigma_1}{\sigma_n} \geq 1$

Conditionnement d'une fonction

f fonction deux fois différentiable

Conditionnement de f en x = nombre de conditionnement de $A = H(x)$

Interprétation

Vecteur propre d_k associé à la valeur propre $\sigma_k : A_k d_k = \sigma_k d_k$

Courbure de f en x dans la direction $d_k : \frac{d_k^T H(x) d_k}{d_k^T d_k} = \sigma_k$

Théorème de Rayleigh-Ritz

d_1 = direction de plus forte courbure (*courbure* = σ_1)

d_n = direction de plus faible courbure (*courbure* = σ_n)

L'interprétation géométrique est importante :

- on a vu que $d^T H_f(x) d / d^T d$ représentait la courbure de f en x dans la direction d .
- si on prend maintenant un vecteur propre d_k de H_f , on a $H_f(x) d_k = \lambda_k d_k$. En multipliant des deux côtés par d_k^T , on obtient que λ_k est la courbure de H_f dans la direction d_k .

Rappel : une valeur propre λ_k est telle que $A x_k = \lambda_k x_k$ pour un vecteur propre $x_k \neq 0$.

Donc $(A - \lambda_k I) \cdot x_k = 0$, et comme $x_k \neq 0$, il faut donc que $\det(A - \lambda_k I) = 0$.

- l'ensemble des valeurs propres $\{\lambda_k\}$ contient les solutions de cette équation.
- le vecteur propre x_k associé à la valeur propre λ_k est obtenu en résolvant l'équation $(A - \lambda_k I) \cdot x_k = 0$ (n équations à n inconnues). La solution x_k est définie à une constante proportionnelle près.

Exemple :

Matrice 2×2

- l'inverse de $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$ est $A^{-1} = \frac{1}{\det(A)} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$ avec $\det(A) = ad - bc$
- Valeurs propres : $\det(A - \sigma I) = 0 \Rightarrow (a - \sigma)(d - \sigma) - bc = 0$
 $\Rightarrow \sigma^2 - (a + d)\sigma + \det(A) = 0$

Conditionnement

- $A = \begin{pmatrix} 0.1 & 1 \\ 0.20002 & 2 \end{pmatrix}$
- Valeurs propres : $\sigma^2 - 2.1\sigma - 0.00002 = 0 \Rightarrow \begin{cases} \sigma_1 = 2.10001 \\ \sigma_2 = -0.00001 \end{cases}$
- Conditionnement : $\begin{cases} \|A\|_2 = \sigma_1 \\ \|A^{-1}\|_2 = 1/\sigma_2 \end{cases} \Rightarrow \kappa(A) = \frac{\sigma_1}{\sigma_2} = 210001$

Donc la matrice A est sensible aux perturbations.

8.3 Préconditionnement

Le preconditionnement permet de modifier le conditionnement d'une matrice afin de stabiliser le comportement numérique des algorithmes.

Changement de variable

Variable : $\tilde{x} = Mx$ ($M \in \mathbb{R}^{n \times n}$ inversible = matrice de preconditionnement)


Fonction : $\tilde{f}(\tilde{x}) = f(x) = f(M^{-1}\tilde{x})$

$$\begin{aligned} \text{Gradient} : \nabla \tilde{f}(\tilde{x}) &= M^{-T} \nabla f(M^{-1} \tilde{x}) \Rightarrow \tilde{g}(\tilde{x}) = M^{-T} g(x) \\ \text{Hessien} : \nabla^2 \tilde{f}(\tilde{x}) &= M^{-T} \nabla^2 f(M^{-1} \tilde{x}) M^{-1} \Rightarrow H(\tilde{x}) = M^{-T} H(x) M^{-1} \end{aligned}$$

Préconditionnement de f

Factorisation de Cholesky (si $H(x)$ définie positive) : $H(x) = LL^T$

Conditionnement optimal minimal de f en x pour : $\tilde{x} = L^T x \Rightarrow \tilde{H}(\tilde{x}) = I \Rightarrow \kappa(\tilde{H}) = 1$



Autrement dit, le conditionnement optimal est celui qui fait en sorte que les courbures soient sensiblement identiques dans toutes les directions.

8.4 Système linéaire perturbé

a) Analyse

On regarde l'effet d'une perturbation sur le second membre d'une équation linéaire.

Perturbation du second membre

Système non perturbé : $Ax = b \Rightarrow$ solution x^*

Système perturbé au 2nd membre : $A(x + \Delta x_b) = b + \Delta b \Rightarrow$ solution $x^* + \Delta x_b$

Système perturbé au 1^{er} membre : $(A + \Delta A)(x + \Delta x_A) = b_A \Rightarrow$ solution $x^* + \Delta x_A$

$$\begin{cases} Ax^* &= b \\ A(x^* + \Delta x_b) &= b + \Delta b \\ (A + \Delta A)(x^* + \Delta x_A) &= b \end{cases} \Rightarrow \begin{cases} Ax^* &= b \\ A.\Delta x_b &= \Delta b \\ A.\Delta x_A + \Delta A.x^* &= 0 \end{cases} \Rightarrow \begin{cases} b &= Ax^* \\ \Delta x_b &= A^{-1}\Delta b \\ \Delta x_A &= -A^{-1}.\Delta A.x^* \end{cases}$$

Majoration de la perturbation

$$\begin{aligned} b = Ax^* &\Rightarrow \|b\| \leq \|A\|.\|x^*\| \Rightarrow \frac{1}{\|x^*\|} \leq \frac{\|A\|}{\|b\|} \\ \begin{cases} \Delta x_b = A^{-1}\Delta b \\ \Delta x_A = -A^{-1}.\Delta A.x^* \end{cases} &\Rightarrow \begin{cases} \|\Delta x_b\| \leq \|A^{-1}\|.\|\Delta b\| \\ \|\Delta x_A\| \leq \|A^{-1}\|.\|\Delta A\|.\|x^*\| \end{cases} \\ &\Rightarrow \begin{cases} \frac{\|\Delta x_b\|}{\|x^*\|} \leq \|A\|.\|A^{-1}\|.\frac{\|\Delta b\|}{\|b\|} \\ \frac{\|\Delta x_A\|}{\|x^*\|} \leq \|A\|.\|A^{-1}\|.\frac{\|\Delta A\|}{\|A\|} \end{cases} \end{aligned}$$

Amplification maximale de la perturbation : $\kappa(A) = \|A\|.\|A^{-1}\|$

On retrouve bien que l'amplification maximale de la perturbation est égale au conditionnement.

b) Exemple

On perturbe le système comme suit :


- $\delta a = +0.001$ sur le terme a_{11} de la matrice A ,
- $\delta b = +0.01$ sur le terme b_1 du vecteur b .

Système perturbé 2×2

$$\begin{cases} 0.1x_1 + x_2 = 2 \\ 0.20002x_1 + 2x_2 = 4.0002 \end{cases} \Leftrightarrow \begin{pmatrix} 0.1 & 1 \\ 0.20002 & 2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 4.0002 \end{pmatrix} \Rightarrow \begin{cases} x_1 = 10 \\ x_2 = 1 \end{cases}$$

$$\text{Perturbation } \delta A : A = \begin{pmatrix} 0.101 & 1 \\ 0.20002 & 2 \end{pmatrix} \Rightarrow \begin{cases} x_1 = -0.101 \\ x_2 = 2.010 \end{cases}$$

$$\text{Perturbation } \delta b : b = \begin{pmatrix} 2.01 \\ 4.0002 \end{pmatrix} \Rightarrow \begin{cases} x_1 = -990 \\ x_2 = 101.01 \end{cases}$$



8.5 Mise à l'échelle

Donc, un préconditionnement permet d'améliorer le comportement des algorithmes. Ceci se fait en général avec des mises à l'échelle.

Principe

- Des valeurs numériques trop différentes sont sources de blocage des algorithmes.
Exemple : $(1 + 10^{-20}) - 1 = 1 - 1 = 0$ au lieu de 10^{-20} avec 16 chiffres significatifs
- Pour réduire les erreurs numériques, il faut que les différentes valeurs utilisées dans les calculs aient des ordres de grandeur comparables.
- Méthode de mise à l'échelle : transformation affine $X' = \alpha X + \beta$

Quantités à mettre à l'échelle

Variables	: $x \rightarrow x' \approx 1$	$\Rightarrow$ déplacement sur toutes les composantes de x)
Critère	: $f \rightarrow f' \approx 1$	$\Rightarrow$ tests d'arrêt sur variation de f)
Contraintes	: $c \rightarrow c' \approx 1$	$\Rightarrow$ contraintes de poids équivalents
Jacobien	: $\ \nabla c\ \rightarrow \ \nabla c'\ \approx 1$	$\Rightarrow$ directions admissibles
Hessien	: $\ \nabla^2 L\ \rightarrow \ \nabla^2 L'\ \approx 1$	$\Rightarrow$ courbure, conditionnement

Difficultés

- On ne peut pas simultanément mettre toutes les quantités à l'échelle $\Rightarrow$ choix expérimental
- Le facteur d'échelle dépend du point $x \Rightarrow$ à adapter au cours des itérations
(mise à l'échelle dynamique)

9 Conclusion

Nous avons seulement les notions de bases utilisées dans les méthodes d'optimisation pour des fonctions différentiables.

En particulier,

- la formulation de base du problème de l'optimisation, ainsi que la caractérisation d'une solution.
- la différentiabilité pour des fonctions multivariées de $\mathbb{R}^n$,
- le théorème de Taylor permettant de définir une estimation polynomiale locale d'une surface (ordre 1 et 2),
- le problème de calcul des dérivées numériques (estimation, erreurs),
- un rappel sur quelques propriétés matricielles,
- comment caractériser la convexité pour une fonction multivariée,
- les problèmes liés au conditionnement des matrices lors d'un calcul numérique

Dans les chapitres suivants, nous utiliserons ces outils afin de faire des recherches d'optimum.

