

Chapitre II

Optimisation sans contrainte

Dans cette leçon, nous verrons dans le cas où il n'y a pas de contrainte :

- Les conditions d'optimalité sans contrainte,
- Comment choisir la direction de déplacement à partir d'un point de départ,
- la résolution d'équation (= recherche de 0) avec la méthode de Newton,
- la minimisation d'équation avec la méthode de Newton,
- les méthodes de minimisation par recherche linéaire,
- la méthode directe de minimisation.

Rappel : la quasi-totalité des transparents de ce cours provient du cours d'optimisation de Max Cerf (Université Paris 6 / Ariane Espace).

1 Condition d'optimalité

1.1 Conditions nécessaires d'un problème sans contraintes

Soit le problème d'optimisation : $\min_{x \in \mathbb{R}^n} f(x)$

$$x^* \text{ minimum local} \Rightarrow \begin{cases} \nabla f(x^*) = 0 & \Rightarrow \text{ordre 1 : point critique ou stationnaire} \\ \nabla^2 f(x^*) \geq 0 & \Rightarrow \text{ordre 2 : hessien semi-défini positif} \end{cases}$$

Preuve : avec le théorème de Taylor

- **Ordre 1 :** $f(x^* + d) = f(x^*) + \nabla f(x^*)^T d + o(\|d\|)$

Si $\nabla f(x^*) \neq 0$, on peut trouver d petit tel que $\nabla f(x^*)^T d < 0$

$\Rightarrow f(x^* + d) < f(x^*) \Rightarrow$ on n'est pas au minimum.

A l'ordre 1, le minimum est atteint lorsque $\nabla f(x^*)^T = 0$.

- **Ordre 2 :**
$$\begin{aligned} f(x^* + d) &= f(x^*) + \nabla f(x^*)^T d + \frac{1}{2} d^T \nabla^2 f(x^*) d + o(\|d\|^2) \\ &= f(x^*) + \frac{1}{2} d^T \nabla^2 f(x^*) d + o(\|d\|^2) \text{ car } \nabla f(x^*) = 0 \end{aligned}$$

Si $\nabla^2 f(x^*)$ non semi-définie positive, par définition, il existe un d petit tel que $d^T \nabla^2 f(x^*) d < 0$

$\Rightarrow f(x^* + d) < f(x^*) \Rightarrow$ on n'est pas au minimum.

À l'ordre 2, le minimum est atteint lorsque $\nabla^2 f(x^*) \geq 0$.

1.2 Conditions nécessaires d'un problème sans contraintes

Soit le problème d'optimisation : $\min_{x \in \mathbb{R}^n} f(x)$

$$\begin{cases} \nabla f(x^*) = 0 & \Rightarrow \text{ordre 1 : point critique ou stationnaire} \\ \nabla^2 f(x^*) > 0 & \Rightarrow \text{ordre 2 : hessien défini positif} \end{cases} \Rightarrow x^* \text{ minimum local}$$

Preuve : par l'absurde

Si x^* n'est pas un minimum local, on peut trouver d petit tel que $f(x^* + d) < f(x^*)$

Or, le théorème de Taylor à l'ordre 2 donne :

$$\begin{aligned} f(x^* + d) &= f(x^*) + \nabla f(x^*)^T d + \frac{1}{2} d^T \nabla^2 f(x^*) d + o(\|d\|^2) \\ &= f(x^*) + \frac{1}{2} d^T \nabla^2 f(x^*) d + o(\|d\|^2) \quad \text{car } \nabla f(x^*) = 0 \end{aligned}$$

or, s'il existe un d tel que $f(x^* + d) < f(x^*) \Rightarrow d^T \nabla^2 f(x^*) d < 0$

$\Rightarrow$ contredit l'hypothèse $\nabla^2 f(x^*)$ définie positive.

1.3 Méthode pratique

Pour résoudre un problème d'optimisation sans contrainte $\min_{x \in \mathbb{R}^n} f(x)$, il faut vérifier :

- condition nécessaire du 1^{er} ordre : $\nabla f(x^*) = 0 \Rightarrow$ point critique ou stationnaire
- condition nécessaire du 2^{ème} ordre : $\nabla^2 f(x^*) \geq 0 \Rightarrow$ plus difficile à vérifier
- condition suffisante du 2^{ème} ordre : $\nabla^2 f(x^*) > 0$

Comment faire ?

- **Recherche des points stationnaires en résolvant : $\nabla f(x^*) = 0$**

Un point stationnaire peut être un minimum local, un maximum local ou un point selle.

- **Vérification de la condition d'ordre 2 :**

calcul des dérivées secondes

puis valeurs propres du hessien ≥ 0 **ou** méthode des sous-déterminants positifs

$\Rightarrow$ garantit l'obtention d'un minimum local x^*

Comment déterminer si x^* est un minimum global ?

f convexe $\Rightarrow x^*$ minimum global

f strictement convexe $\Rightarrow x^*$ unique minimum global

f quelconque (cas général) $\Rightarrow$ on ne peut pas le vérifier.

1.4 Exemples

a) Exemple 1

Fonction de Rosenbrock $f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$

Gradient : $\nabla f(x_1, x_2) = \begin{pmatrix} 400x_1^3 - 400x_1x_2 + 2x_1 - 2 \\ 200x_2 - 200x_1^2 \end{pmatrix}$

Hessien : $\nabla^2 f(x_1, x_2) = \begin{pmatrix} 1200x_1^2 - 400x_2 + 2 & -400x_1 \\ -400x_1 & 200 \end{pmatrix}$

Point stationnaire : $\nabla f(x_1, x_2) = 0 \Rightarrow \begin{cases} 400x_1^3 - 400x_1x_2 + 2x_1 - 2 = 0 \\ 200x_2 - 200x_1^2 = 0 \end{cases}$


$$\Rightarrow \begin{cases} x_1 = 1 \\ x_2 = x_1^2 \end{cases} \Rightarrow x^* = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

Hessien défini positif? $\nabla^2 f(x^*) = \begin{pmatrix} 802 & -400 \\ -400 & 200 \end{pmatrix} \Rightarrow D_1 = 802, D_2 = 400 \Rightarrow \text{ok}$

Condition d'ordre 2 : $\nabla^2 f(x^*)$ est défini positif.

x^* vérifie les conditions suffisantes de minimum local (*strict*)

x^* est un minimum local de f



b) Exemple 2

Fonction : $f(x_1, x_2) = -x_1^4 - x_2^4$

Gradient : $\nabla f(x_1, x_2) = \begin{pmatrix} -4x_1^3 \\ -4x_2^3 \end{pmatrix}$

Hessien : $\nabla^2 f(x_1, x_2) = \begin{pmatrix} -12x_1^2 & 0 \\ 0 & -12x_2^2 \end{pmatrix}$

Point stationnaire : $\nabla f(x_1, x_2) = 0 \Rightarrow \begin{cases} x_1 = 0 \\ x_2 = 0 \end{cases} \Rightarrow x^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Hessien défini positif? $\nabla^2 f(x^*) = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow D_1 = 0, D_2 = 0$
 $\Rightarrow \nabla^2 f(x^*)$ est semi-défini positif

x^* vérifie les conditions nécessaires de minimum local

x^* ne vérifie pas les conditions suffisantes de minimum local

x^* est en fait un **maximum local** de f :

$$f(x_1, x_2) = -x_1^4 - x_2^4 \leq 0 \Rightarrow \forall (x_1, x_2), f(x_1, x_2) \leq f(0, 0)$$

c) Exemple 3

Fonction : $f(x_1, x_2) = x_1^2 - x_2^3$

Gradient : $\nabla f(x_1, x_2) = \begin{pmatrix} 2x_1 \\ -3x_2^2 \end{pmatrix}$

Hessien : $\nabla^2 f(x_1, x_2) = \begin{pmatrix} 2 & 0 \\ 0 & -6x_2 \end{pmatrix}$

Point stationnaire : $\nabla f(x_1, x_2) = 0 \Rightarrow \begin{cases} x_1 = 0 \\ x_2 = 0 \end{cases} \Rightarrow x^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

Hessien défini positif ? en x^* , $\nabla^2 f(x^*) = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix} \Rightarrow D_1 = 2, D_2 = 0$


$\Rightarrow \nabla^2 f(x^*)$ est semi-défini positif

x^* vérifie les conditions nécessaires de minimum local

x^* ne vérifie pas les conditions suffisantes de minimum local

x^* n'est ni un minimum ni un maximum local de f :

$$f(0, x_2) = \begin{cases} -x_2^3 < 0 & \text{si } x_2 > 0 \\ -x_2^3 > 0 & \text{si } x_2 < 0 \end{cases}$$



2 Principes de minimisation

2.1 Panel des méthodes

Problème non linéaire sans contraintes : $\min_{x \in \mathbb{R}^n} f(x)$ problème noté (PO)

Différentes méthodes de résolution :

Méthodes globales (non étudiée dans ce cours)

capacité à localiser plusieurs minima locaux (éventuellement le minimum global)

exemples : algorithmes génétiques, recuit simulé, colonies de fourmis, ...

convergence généralement lente, peu précise

voir le cours de Max Cerf pour une première approche.

Méthodes locales

- **Recherche d'un minimum local à partir d'un point initial fourni par l'utilisateur**
- **Utilise les développements de Taylor (limité jusqu'à un ordre)**
 - d'ordre 0 : sans dérivées $\Rightarrow$ Nelder-Mead, Direct
 - d'ordre 1 : avec dérivées premières $\Rightarrow$ plus forte pente
 - d'ordre 2 : avec dérivées premières et secondes $\Rightarrow$ Newton
- **Critères d'efficacité :**
 - rapidité** de convergence (nombre d'appels de la fonction)
 - précision** de convergence
 - robustesse** à l'initialisation

Dans ce cours, on se restreint aux méthodes locales.

2.2 Principe

On a déjà vu que :


Le problème se formule : $\min_{x \in \mathbb{R}^n} f(x)$

Si x^* minimum local, alors $\begin{cases} \nabla f(x^*) = 0 \\ \nabla^2 f(x^*) \geq 0 \end{cases}$

On ne sait pas trouver le minimum global dans le cas général (f quelconque)

Principe d'une méthode locale :

- Initialisation $x_0 \Rightarrow$ recherche d'un minimum local au voisinage de x_0
- Itérations $\Rightarrow$ passage du point x_k au point x_{k+1} meilleur
- Arrêt $\Rightarrow$ solution x^* ou blocage



Modèle local : prédiction

- La fonction étant en général quelconque, on prédit un déplacement qui devrait améliorer le critère à partir d'une approximation locale de la fonction.
- Point courant $x_k : f_k = f(x_k)$
- Évaluation de $g_k = \nabla f(x_k)$ ou approximation (différences finies)
 $H_k = \nabla^2 f(x_k)$ ou approximation (quasi Newton)
- Modèle quadratique : $\min_p \hat{f}_k(x_k + p) = f_k + p^T g_k + \frac{1}{2} p^T H_k p$
 $\Rightarrow \hat{x}_{k+1} = x_k + \hat{p}$ (prédiction)
 $\Rightarrow$ Méthodes de Newton ou quasi-Newton

Amélioration : correction

- Nouveau point $x_{k+1} = x_k + p$ tel que $f(x_k + p) < f(x_k)$
- La méthode de Newton appliquée directement ne converge pas systématiquement. On utilise normalement la globalisation pour contrôler la convergence.
- Méthodes de globalisation : déplacement p à partir de x_k
 par recherche linéaire suivant $d_k = \hat{x}_{k+1} - x_k$
 par région de confiance dans $\|x - x_k\| < r$
 La globalisation n'est pas abordée dans ce cours (voir celui de Max Cerf).

Initialisation

- Les **méthodes locales** recherchent le minimum au voisinage du point de départ.
- Objectifs : rapidité de convergence
 précision de convergence
 $\Rightarrow$ méthodes à base de dérivées

Le minimum local trouvé est le plus proche du point initial x_0 .

$\Rightarrow$ initialisation à modifier pour trouver un autre minimum local

- Les **méthodes "globales"** explorent "aléatoirement" les solutions
 $\Rightarrow$ localisation possible de plusieurs minima locaux

Conditions d'arrêt


- Déplacement insuffisant : $\|x_{k+1} - x_k\| < \varepsilon_x$
- Amélioration insuffisante : $f_k - f_{k+1} < \varepsilon_f$
- Condition d'ordre 1 vérifiée : $\|g_k\| < \varepsilon_g$
- Nombre maximal d'itérations ou d'appels fonction : $N_{\text{iter}}, N_{\text{fonc}}$

3 Direction de descente

3.1 Descente du gradient

Comment choisir la direction de déplacement pour une méthode locale ?

- Gradient de f en $x \in \mathbb{R}^n$: $g(x) = \nabla f(x)$
- Dérivée directionnelle de f en x suivant $d \in \mathbb{R}^n$: $f_d(x) = g(x)d^T$
 d est une **direction de descente en x** si : $f_d(x) = g(x)^T d < 0$
- La **direction de plus forte pente d^+** est la **direction du gradient** : $d^+ = g(x)$
- La **direction de plus forte descente d^-** est **opposée au gradient** : $d^- = -g(x)$
 $\forall d \in \mathbb{R}^n / \|d\| = \|d^-\| = 1, g(x)^T d \geq g(x)^T d^- = -\|g(x)\|^2$




3.2 Expression en fonction du pas de descente

Exprimons un déplacement directionnel en fonction du pas de descente.

- Déplacement $d \in \mathbb{R}^n$ à partir de $x_0 \in \mathbb{R}^n$: $d = s d_0$
 $d_0 \in \mathbb{R}^n$ = direction de déplacement, et $s \in \mathbb{R}$ = pas de déplacement suivant d_0
- Modèle quadratique au voisinage de x_0 : $\varphi(s) = f(x_0 + s d_0)$ fonction de $\mathbb{R}$ dans $\mathbb{R}$

$$f(x_0 + s d_0) = f(x_0) + s g_0^T d_0 + \frac{1}{2} s^2 d_0^T H_0 d_0 \text{ où } \begin{cases} g_0 = \nabla f(x_0) \\ H_0 = \nabla^2 f(x_0) \end{cases}$$

$$\Rightarrow \hat{\varphi}(s) = \varphi(0) + s \varphi'(0) + \frac{1}{2} s^2 \varphi''(0) \text{ où } \begin{cases} \varphi'(0) = g_0^T d_0 \\ \varphi''(0) = d_0^T H_0 d_0 \end{cases}$$



Notons que la meilleure direction n'est pas nécessairement la descente du gradient, mais que cette dernière permet toujours de descendre.

3.3 Minimisation locale

Deux points particuliers sont définis à partir du modèle quadratique de f en x_0 :

a) Point de Newton

Le point de Newton minimise de f par rapport à $d \in \mathbb{R}^n \Rightarrow x_n = x_0 + d_n$

Cherchons le minimum par rapport à d .

On calcule :

$$\frac{\partial \hat{f}(x_0 + d)}{\partial d} = \frac{\partial}{\partial d} \left(f(x_0) + g_0^T d + \frac{1}{2} d^T H_0 d \right) = g_0 + H_0 d.$$

On résout :

$$g_0 + H_0 d = 0 \quad \Rightarrow \quad d_N = -H_0^{-1} g_0.$$


Si $H_0 = \nabla^2 f(x_0)$ est définie positive¹, alors on est bien sur un minimum.

Le point suivant (dit de Newton) est choisi comme : $x_N = x_0 + d_N$.

Point de Newton = déplacement obtenu par la minimisation de l'approximation de f à l'ordre 2.

Note : En 2D, si le Hessien est défini positif, l'approximation de la fonction donne des courbes de niveau elliptique.

1. **rappel :** CNS d'un minimum local $\nabla f = 0$ et $\nabla^2 f = 0$).



b) Point de Cauchy

Le point de Cauchy minimise de f dans la direction $d_0 = -g_0 \Rightarrow x_c = x_0 - s_c g_0$

On force à se déplacer dans la direction inverse du gradient avec $x_c = x_0 - s_c g_0$.

Prenons l'approximation à l'ordre 2 de $\varphi(s)$ en x_0 :

$$\hat{\varphi}(x) = \varphi(0) + g_0^\top (x - x_0) + \frac{1}{2}(x - x_0)^\top H_0 (x - x_0)$$

et calculons son gradient :

$$\nabla \hat{\varphi}(x) = g_0 + H_0(x - x_0).$$

puis, évaluons-le au point $x = x_0 - s_c g_0$:

$$\nabla \hat{\varphi}(x_0 - s_c g_0) = g_0 - s_c H_0 g_0.$$

On veut maintenant le s qui minimise $\hat{\varphi}(x_0 - s g_0)$, donc tel que $\frac{d}{ds} \hat{\varphi}(x_0 - s g_0) = 0$

$$\begin{aligned} \frac{d}{ds} \hat{\varphi}(x_0 - s g_0) &= \nabla \hat{\varphi}(x_0 - s g_0)^\top (-g_0) \\ &= (g_0 - s H_0 g_0)^\top (-g_0) = -\|g_0\|^2 + s (g_0^\top H_0 g_0) = 0 \end{aligned}$$

On résout en s_c :

$$s_c = \frac{\|g_0\|^2}{g_0^\top H_0 g_0}.$$

s_c existe si $g_0^\top H_0 g_0 > 0$ (défini positif, CNS ordre 2 du minimum).

Donc $x_c = x_0 - s_c g_0$ existe si f est convexe suivant g_0 .

Notons que **cette condition est moins forte que H_0 définie positive.**

Voir graphique précédent pour la différence avec le point de Cauchy.

4 Résolution d'équation du type $g(x) = 0$ dans $\mathbb{R}^n$

On s'intéresse dans un premier temps à la recherche de 0 pour une fonctionnelle g .


Système d'équations non linéaires

$g(x) = 0$ avec $g : \mathbb{R}^n \rightarrow \mathbb{R}^n \Rightarrow$ système de n équations à n inconnues

4.1 Principe

On veut appliquer la méthode suivante :

- Linéariser g au point initial $x_0 \Rightarrow$ fonction modèle linéaire $\hat{g}$ "proche" de g
- Résoudre le système linéaire $\hat{g}(x) = 0 \Rightarrow$ nouveau point x_1
- Itérer jusqu'à vérifier $g(x) = 0 \Rightarrow$ solution x^*



4.2 Méthode de Newton

Voyons maintenant la méthode de Newton.

a) Principe

Fonction modèle

- Développement de Taylor à l'ordre 1 de g en x_k

$$g(x) = g(x_k) + \nabla g(x_k)^T (x - x_k) + o(\|x - x_k\|)$$
- Modèle linéaire de g en x_k :

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } G_k \in \mathbb{R}^{n \times n}$$

Choix de la matrice G_k

- **Méthode de Newton** $\Rightarrow G_k = \nabla g(x)_k^T =$ gradient de g en x_k
- **Méthode de quasi-Newton** $\Rightarrow G_k =$ approximation de $\nabla g(x)_k^T$


Résolution

- Système linéaire : $\hat{g}_k(x) = 0 \Rightarrow g(x_k) + G_k(x - x_k) = 0$
 on résout en x , ce qui donne : $x = x_k - G_k^{-1}g(x_k)$, d'où l'itération :
- Itération : $x_{k+1} = x_k - G_k^{-1}g(x_k)$ si G_k inversible
- Condition d'arrêt : $\|g(x_k)\| < \varepsilon$

b) Cas $x \in \mathbb{R}$

Dans le cas où x est une variable, l'expression devient

- **Équation non linéaire** : $g(x) = 0$
- **Point initial** : $(x_0, y_0) = (x_0, g(x_0)) \Rightarrow$ Tangente en x_0 : $y = y_0 + g'(x_0)(x - x_0)$
- **Intersection axe x** : $y = 0 \Rightarrow x_1 = x_0 - \frac{y_0}{g'(x_0)}$
- **Nouveau point** : $(x_1, y_1) = (x_1, g(x_1))$



Géométriquement, le point choisit pour la prochaine itération est la position de la sécante sur l'axe des x .

c) Erreur due à la linéarisation

La fonction est remplacée par son approximation linéaire :

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } G_k = \nabla g(x_k)^T$$

Évaluation de l'erreur de linéarisation :

En notant M = constante de Lipschitz sur le gradient $\approx$ majorant de la courbure

$$\|g(x) - \hat{g}_k(x)\| \leq \frac{1}{2}M\|x - x_k\|^2 \Rightarrow \text{erreur quadratique}$$

Ceci vient du fait que lorsqu'on prend le développement de Taylor de $g(x)$ et qu'on lui soustrait son approximation d'ordre 1, il reste un terme qui majoré par son approximation d'ordre 2 quand $\|x - x_k\|$ est petit.

d) Vitesse de convergence

Hypothèses sur la solution x^* :

$\nabla g(x^*)$ inversible = descente de gradient possible

$\|\nabla g(x^*)^{-1}\| \leq \eta$ = il n'explose pas !

Regardons le comportement de la suite (x_k) : $x_{k+1} = x_k - G_k^{-1}g(x_k)$

- **La suite (x_k) converge vers x^* si x est "assez proche" de x^***

$$\exists r > 0 \mid \|x - x^*\| < r \Rightarrow \lim_{k \rightarrow \infty} x_k = x^*$$

- **La convergence est quadratique** (=on s'approche vite de la solution)

$$\Rightarrow \|x_{k+1} - x^*\| \leq M\eta\|x_k - x^*\|^2$$

e) Exemples


Exemple 1

- Fonction : $g(x) = x^2 - 1$
- Dérivée : $g'(x) = 2x$
- **Solution** : $x = 1 \Rightarrow g'(1) = 2$

Convergence quadratique : remarquer l'erreur

$10^{-1} \rightarrow 10^{-2} \rightarrow 10^{-4} \rightarrow \dots$

$g'(x^*) = 2$ est bien inversible.



k	x_k	$g(x)$	$g'(x)$	Erreur
0	4,00000000	1,5E+01	8,0000	3,0E+00
1	2,12500000	3,5E+00	4,2500	1,1E+00
2	1,29779412	6,8E-01	2,5956	3,0E-01
3	1,03416618	6,9E-02	2,0683	3,4E-02
4	1,00056438	1,1E-03	2,0011	5,6E-04
5	1,00000016	3,2E-07	2,0000	1,6E-07
6	1,00000000	2,5E-14	2,0000	1,3E-14


Exemple 2

- Fonction : $g(x) = (x - 1)^2$
- Dérivée : $g'(x) = 2(x - 1)$
- **Solution** : $x = 1 \Rightarrow g'(1) = 0$

Convergence lente


$g'(x^*) = 0$ non inversible

Iteration	$x(k)$	$g(x)$	$g'(x)$	Erreur
0	4,00000000	9,0E+00	6,0000	3,0E+00
1	2,50000000	2,3E+00	3,0000	1,5E+00
2	1,75000000	5,6E-01	1,5000	7,5E-01
3	1,37500000	1,4E-01	0,7500	3,8E-01
4	1,18750000	3,5E-02	0,3750	1,9E-01
5	1,09375000	8,8E-03	0,1875	9,4E-02
6	1,04687500	2,2E-03	0,0938	4,7E-02
7	1,02343750	5,5E-04	0,0469	2,3E-02
8	1,01171875	1,4E-04	0,0234	1,2E-02
9	1,00585938	3,4E-05	0,0117	5,9E-03
10	1,00292969	8,6E-06	0,0059	2,9E-03
15	1,00009155	8,4E-09	0,0002	9,2E-05
20	1,00000286	8,2E-12	0,0000	2,9E-06



Exemple 3

- Fonction : $g(x) = \text{Arctan}(x)$
- Dérivée : $g'(x) = \frac{1}{1+x^2}$
- Solution : $x = 0 \Rightarrow g''(1) = 0$



Iteration	$x(k)$	$g(x)$	$g'(x)$	Erreur
0	1,300	0,915	0,372	1,3E+00
1	-1,162	-0,860	0,426	-1,2E+00
2	0,859	0,710	0,575	8,6E-01
3	-0,374	-0,358	0,877	-3,7E-01
4	0,034	0,034	0,999	3,4E-02
5	0,000	0,000	1,000	-2,6E-05
6	0,000	0,000	1,000	1,2E-14

$\Rightarrow$ convergence (x_k assez près du minimum pour converger)

Iteration	$x(k)$	$g(x)$	$g'(x)$	Erreur
0	1,500	0,983	0,308	1,5E+00
1	-1,694	-1,038	0,258	-1,7E+00
2	2,321	1,164	0,157	2,3E+00
3	-5,114	-1,378	0,037	-5,1E+00
4	32,296	1,540	0,001	3,2E+01
5	-1575,317	-1,570	0,000	-1,6E+03
6	3894976,008	1,571	0,000	3,9E+06

$\Rightarrow$ divergence (x_k trop loin du minimum pour converger)

f) Exercices**EXERCICE 14: Recherche d'un zéro par la méthode de Newton (1)**

Soit la fonction $f(x) = e^{x-3} + x - 2$. On veut trouver la valeur de x_0 telle que $f(x_0) = 0$.

1. calculer la dérivée de $f(x)$.
2. en partant de $x = 2$, utiliser le méthode de Newton pour trouver le 0.

EXERCICE 15: Recherche d'un zéro par la méthode de Newton (2)

Soit la fonction $f(x) = \cos x$. On veut trouver la valeur de x_0 telle que $f(x_0) = 0$.

1. calculer la dérivée de $f(x)$.
2. en partant de $x = 1$, utiliser le méthode de Newton pour trouver le 0.
3. que peut-on dire du zéro trouvé?

g) Conclusion**Intérêt de la méthode de Newton**

- Convergence quadratique au voisinage de la solution $\Rightarrow$ **très rapide et précise**
- Méthode à privilégier dans les algorithmes d'optimisation

Difficultés

- Calcul explicite du gradient $\nabla g(x_k)$ à chaque itération
 $\Rightarrow$ coûteux (n appels fonctions)
- Convergence non garantie $\Rightarrow$ même près de la solution

Adaptations

- **Méthodes de quasi-Newton** $\rightarrow G_k =$ approximation du gradient $\nabla g(x)_k$

construite à partir des itérations précédentes
sans calcul explicite du gradient

- pour aller plus loin voir les **techniques de globalisation** (cf cours Max Cerf)

idée : contrôle du point x_{k+1} (meilleur que x_k ?)

vérification $\|g(x_{k+1})\| < \|g(x_k)\|$.

si pas satisfaisant $\Rightarrow$ méthodes de recherche linéaire pour minimiser $\|g(x)\|^2$.

4.3 Méthode de quasi-Newton

On rappelle que $G_k = \nabla g(x_k)^T$, où g est la fonction dont on recherche le zéro.

a) Méthode de Broyden

On cherche à définir la matrice G_k à partir de la matrice G_{k-1} de l'itération précédente.

Les matrices G_{k-1} et G_k doivent être "proches" au sens de la norme matricielle.

Contrainte de construction de G_k : $G_k(x_k - x_{k-1}) = g(x_k) - g(x_{k-1})$ afin de satisfaire la relation de la sécante.

Variation de modèle

- Par définition, $g(x_k) = g(x_{k-1}) + G_k(x_k - x_{k-1})$
- Modèle linéaire de g en x_{k-1} : $\hat{g}_{k-1}(x) = g(x_{k-1}) + G_{k-1}(x - x_{k-1})$
- Modèle linéaire de g en x_k : $\hat{g}_k(x) = g(x_k) + G_k(x - x_k)$

- Différence entre les modèles en x et x_{k-1}

$$\begin{aligned}\hat{g}_k(x) &= g(x_k) + G_k(x - x_k) \\ &\text{comme } g(x_k) = g(x_{k-1}) + G_k(x_k - x_{k-1}), \text{ on a :} \\ &= g(x_{k-1}) + G_k(x_k - x_{k-1}) + G_k(x - x_k) \\ &= g(x_{k-1}) + G_k(x - x_{k-1}) \\ &\text{modèle linéaire en } x_{k-1} : g(x_{k-1}) = \hat{g}_{k-1}(x) - G_{k-1}(x - x_{k-1}) \\ &= \hat{g}_{k-1}(x) - G_{k-1}(x - x_{k-1}) + G_k(x - x_{k-1}) \\ &= \hat{g}_{k-1}(x) + (G_k - G_{k-1})(x - x_{k-1})\end{aligned}$$

$$\text{d'où } \hat{g}_k(x) - \hat{g}_{k-1}(x) = (G_k - G_{k-1})(x - x_{k-1})$$

Objectif

Conserver un modèle linéaire de g en x_k

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } G_k \approx \nabla g(x_k)^T$$

sans calculer explicitement G_k

Equation de la sécante

On choisit une matrice $G_k \in \mathbb{R}^{n \times n}$ vérifiant $g(x_k) - g(x_{k-1}) = G_k(x_k - x_{k-1})$

$$\Leftrightarrow y_{k-1} = G_k d_{k-1} \text{ avec } \begin{cases} d_{k-1} = x_k - x_{k-1} \\ y_{k-1} = g(x_k) - g(x_{k-1}) \end{cases}$$

$\Rightarrow$ équation de la sécante entre x_{k-1} et x_k

Choix de G

Il existe une infinité de matrices G vérifiant l'équation de la sécante :


- n^2 inconnues (composantes de $G \in \mathbb{R}^{n \times n}$)
- n équations

Chaque ligne de G définit un hyperplan de $\mathbb{R}^n$ passant par x_{k-1} et x_k
 $\Rightarrow$ infinité d'hyperplans possibles.

b) cas $x \in \mathbb{R}$ ($n = 1$)

Dans ce cas, il n'y a plus d'indétermination, et on obtient directement l'expression de $G = \frac{y_k - y_{k-1}}{x_k - x_{k-1}}$.

- Equation non linéaire : $g(x) = 0$
- Points initiaux : $\begin{cases} (x_0, y_0) = (x_0, g(x_0)) \\ (x_1, y_1) = (x_1, g(x_1)) \end{cases} \Rightarrow$ sécante en $x_1 : y = y_0 - \frac{y_1 - y_0}{x_1 - x_0}(x - x_0)$
- Intersection axe $x : y = 0 \Rightarrow x_2 = x_0 - \frac{x_1 - x_0}{y_1 - y_0}y_0$
- Nouveau point : $x_2, y_2 = g(x_2)$



Pour la sécante, la dérivée est estimée par la pente de la droite.

c) Mise à jour de Broyden

Cette mis-à-jour permet d'obtenir un moyen d'obtenir une matrice G_k mise à jour à chaque itération de la manière suivante.

L'écart entre les modèles $\hat{g}_{k-1}(x)$ et $\hat{g}_k(x)$ est minimal en choisissant G_k solution de $\min_{G \in \mathbb{R}^{n \times n}} \|G - G_{k-1}\|$

sous $y_{k-1} = G d_{k-1}$ avec $\begin{cases} d_{k-1} = x_k - x_{k-1} \\ y_{k-1} = g(x_k) - g(x_{k-1}) \end{cases}$

Formule de Broyden :

$$G_k = G_{k-1} + \frac{(y_{k-1} - G_{k-1}d_{k-1})d_{k-1}^T}{d_{k-1}^T d_{k-1}}$$

$\Rightarrow$ solution optimale

Convergence

- La matrice G ne converge pas forcément vers ∇g mais ceci ne compromet pas la convergence.
- Les méthodes de quasi-Newton et de Newton peuvent converger vers des solutions différentes.

- La méthode de quasi-Newton converge généralement moins vite que la méthode de Newton, mais nécessite beaucoup moins d'appels de la fonction g (pas de calcul de gradient).
- noter qu'il y a peu de résultats théoriques sur cette méthode mais qu'elle est efficace en pratique (comportement à vérifier et adapter au cas par cas).

Noter que, pour une fonction $g : \mathbb{R} \mapsto \mathbb{R}$, la formule de Broyden devient :

$$G_k = G_{k-1} + \frac{(y_{k-1} - G_{k-1}d_{k-1})d_{k-1}^T}{d_{k-1}^T d_{k-1}} = G_{k-1} + \frac{y_{k-1}}{d_{k-1}} - G_{k-1} = \frac{y_{k-1}}{d_{k-1}} = \frac{g(x_k) - g(x_{k-1})}{x_k - x_{k-1}}$$

et en conséquence, la mise-à-jour $x_{k+1} = x_{k-1} - y_{k-1}/G_k$ revient bien à la méthode de la sécante avec une estimation de la pente de la droite.

d) Exemple

Comparaison Newton – Quasi-Newton

- Fonction : $g(x) = x^2 - 1$
- Dérivée : $g'(x) = 2x$
- Solution : $x = 1$

Quasi - Newton

Iteration	x_k	$g(x_k)$	dg/dx	Erreur
	5,00000000	2,4E+01		4,0E+00
0	4,00000000	1,5E+01	9,0000	3,0E+00
1	2,33333333	4,4E+00	6,3333	1,3E+00
2	1,63157895	1,7E+00	3,9649	6,3E-01
3	1,21238938	4,7E-01	2,8440	2,1E-01
4	1,04716672	9,7E-02	2,2596	4,7E-02
5	1,00443349	8,9E-03	2,0516	4,4E-03
6	1,00010193	2,0E-04	2,0045	1,0E-04
7	1,00000023	4,5E-07	2,0001	2,3E-07
8	1,00000000	2,3E-11	2,0000	1,1E-11

Newton

Iteration	x_k	$g(x_k)$	$g'(x_k)$	Erreur
0	4,00000000	1,5E+01	8,0000	3,0E+00
1	2,12500000	3,5E+00	4,2500	1,1E+00
2	1,29779412	6,8E-01	2,5956	3,0E-01
3	1,03416618	6,9E-02	2,0683	3,4E-02
4	1,00056438	1,1E-03	2,0011	5,6E-04
5	1,00000016	3,2E-07	2,0000	1,6E-07
6	1,00000000	2,5E-14	2,0000	1,3E-14

e) Exercices

EXERCICE 16: Recherche d'un zéro par la méthode de quasi-Newton (1)

Soit la fonction $f(x) = e^{x-3} + x - 2$. On veut trouver le zéro de $f(x)$ par la méthode de quasi-Newton. On initialisera l'algorithme avec $x_0 = 2$ et $x_1 = 1.9$.

EXERCICE 17: Recherche d'un zéro par la méthode de quasi-Newton (2)

Soit la fonction $f(x) = \cos x$. On veut trouver le zéro de $f(x)$ par la méthode de quasi-Newton. On initialisera l'algorithme avec $x_0 = 1$ et $x_1 = 1.1$.

5 Méthodes d'optimisation de type Newton

On s'intéresse maintenant à la **minimisation** d'une fonctionnelle d'un problème sans contrainte.

Problème sans contrainte $\min_{x \in \mathbb{R}^n} f(x)$

A partir de **maintenant**, on note :

le gradient : $g(x) = \nabla f(x)$

le hessien : $H(x) = \nabla^2 f(x)$

Condition nécessaire de minimum local

$$x^* \text{ minimum local} \Rightarrow \begin{cases} g(x^*) = 0 \\ H(x^*) \geq 0 \text{ (hessien semi-défini positif)} \end{cases}$$

5.1 Principe

On recherche les points stationnaires

On applique la méthode de Newton au système d'équations non linéaires : $g(x) = 0$

On linéarise le modèle de g en x_k (= ordre 1) :

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } \begin{cases} g(x_k) = \nabla f(x_k) \\ G_k = \nabla g(x_k)^T = \nabla^2 f(x_k) = H_k \end{cases}$$

- **Méthode de Newton** : $G = H \Rightarrow$ calcul explicite du hessien à chaque itération.
- **Méthode de quasi-Newton** : G = approximation de H construite à partir des itérations précédentes sans calcul explicite du hessien.

5.2 Méthode de Newton

a) Modèle linéaire

Première approche : on utilise un modèle linéaire de ∇f en x

Modèle linéaire de $g = \nabla f$ en x_k

$$\hat{g}_k(x) = g(x_k) + G_k(x - x_k) \text{ avec } \begin{cases} g(x_k) = \nabla f(x_k) \\ G_k = \nabla g(x_k)^T = \nabla^2 f(x_k) = H_k \end{cases}$$

Itération : $x_{k+1} = x_k - \nabla^2 f(x_k)^{-1} \nabla f(x_k) \Rightarrow$ équations de Newton

Condition d'arrêt : $\|\nabla f(x_k)\| \leq \varepsilon$

Difficultés

- Calcul explicite et inversion du hessien $\nabla^2 f(x_k)$ à chaque itération $\Rightarrow$ coûteux.
- Convergence non garantie même près de la solution
 $\Rightarrow$ mêmes difficultés que pour la résolution d'équations
- 1^{ère} condition nécessaire de minimum : $\nabla f(x^*) = 0$
 $\Rightarrow$ point stationnaire x^* = minimum local, maximum local ou point selle
 $\Rightarrow$ 2^{ème} condition nécessaire de minimum à vérifier : $\nabla^2 f(x^*) \geq 0$

Adaptations

- **Méthodes de quasi-Newton** $\Rightarrow G_k$ = approximation du hessien $\nabla^2 f(x)_k$
- **Techniques de globalisation** $\Rightarrow$ contrôle de la décroissance de f (voir le cours de Max Cerf)

b) Modèle quadratique

Deuxième approche : on utilise un modèle quadratique de f en x , puis on utilise ce modèle afin d'estimer ∇f en x

Modèle quadratique de f en x_k

- Développement de Taylor à l'ordre 2 de f en x_k :

$$f(x) = f(x_k) + \nabla f(x_k)^T(x - x_k) + \frac{1}{2}(x - x_k)^T \nabla^2 f(x_k)(x - x_k) + o(\|x - x_k\|^2)$$

- Modèle quadratique en x_k :

$$f_k(x) = f_k(x_k) + g_k^T(x - x_k) + \frac{1}{2}(x - x_k)^T H_k(x - x_k)$$

- Lien entre le modèle de f et le modèle de $g = \nabla f$:

$$\nabla \hat{f}_k(x) = g_k + H_k(x - x_k) = \hat{g}_k(x)$$

Minimisation du modèle de f en x_k

- Conditions suffisantes de minimum local : $\min_{x \in \mathbb{R}^n} \hat{f}_k(x) \Rightarrow \begin{cases} \nabla \hat{f}_k(x^*) = \hat{g}_k(x^*) = 0 \\ \nabla^2 \hat{f}_k(x^*) = H_k > 0 \end{cases}$
- Si le hessien de f en x_k est défini positif : $\nabla^2 f(x) > 0$

Minimisation du modèle quadratique
de f en x_k

$\Leftrightarrow$


Méthode de Newton en x_k pour
résoudre $\nabla f(x) = 0$

- Sinon la méthode de Newton n'est pas directement applicable pour une minimisation.

Comme précédemment, on utilise Newton avec pour déplacement $x_{k+1} = x_k - H_k^{-1} g_k$

c) Exemple

- Fonction : $f(x) = -x^4 + 12x^3 - 47x^2 + 60x$
- Dérivée : $f'(x) = -4x^3 + 36x^2 - 94x + 60$
 $\Rightarrow 3$ zéros,
 2 maxima locaux dont 1 minimum



Regardons maintenant plus précisément ce qu'il se passe lorsqu'on applique la méthode de Newton aux points $x = 3$, $x = 4$ et $x = 5$.

On a :

$$\begin{aligned} f(x) &= -x^4 + 12x^3 - 47x^2 + 60x \\ \nabla f(x) &= f'(x) = -4x^3 + 36x^2 - 94x + 60 \\ \nabla^2 f(x) &= f''(x) = -12x^2 + 72x - 94 \end{aligned}$$

Le modèle quadratique de f en x_0 est défini par :

$$\hat{f}(x) = f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2}f''(x_0)(x - x_0)^2$$

On évalue :

$$\text{en } x_0 = 3, \quad \hat{f}(3) = 0 - 6(x - 3) + \frac{1}{2}14(x - 3)^2 = 7x^2 - 48x + 81$$

$$\text{en } x_0 = 4, \quad \hat{f}(4) = 0 + 4(x - 4) + \frac{1}{2}2(x - 4)^2 = x^2 - 4x$$


$$\text{en } x_0 = 5, \quad \hat{f}(5) = 0 - 10(x - 5) - \frac{1}{2}34(x - 5)^2 = -17x^2 + 160x - 375$$

Méthode de Newton en $x_0 = 3$

- Modèle quadratique en $x_0 = 3$: $f_0(x) = 7x^2 - 48x + 81$
- Itération de Newton en $x = 3$:

$$x_{k+1} = x_k - H_k^{-1} g_k \stackrel{x_0=3}{\Rightarrow} \begin{cases} f'(x_0) = -6 \\ f''(x_0) = 14 \\ x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 3 - \frac{-6}{14} = \frac{24}{7} \end{cases}$$

$\Rightarrow x_1$ meilleur que x_0 : $f(x_1) = -1.32 < 0 = f(x_0)$



Méthode de Newton en $x_0 = 4$


- Modèle quadratique en $x_0 = 4$: $f_0(x) = x^2 - 4x$

- Itération de Newton en $x = 4$:

$$x_{k+1} = x_k - H_k^{-1} g_k \stackrel{x_0=4}{\Rightarrow} \begin{cases} f'(x_0) = 4 \\ f''(x_0) = 2 \end{cases}$$

$$\Rightarrow x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 4 - \frac{4}{2} = 2$$

$\Rightarrow x_1$ moins bon $x_0 : f(x_1) = 12 > 0 = f(x_0)$



Méthode de Newton en $x_0 = 5$

- Modèle quadratique en $x_0 = 5$: $f_0(x) = -17x^2 + 160x - 375$
- Itération de Newton en $x = 5$:

$$x_{k+1} = x_k - H_k^{-1} g_k \stackrel{x_0=5}{\Rightarrow} \begin{cases} f'(x_0) = 4 \\ f''(x_0) = 2 \end{cases}$$

$$\Rightarrow x_1 = x_0 - \frac{f'(x_0)}{f''(x_0)} = 5 - \frac{-10}{-34} = \frac{80}{17}$$

$\Rightarrow x_1$ moins bon $x_0 : f(x_1) = 1.513 > 0 = f(x_0)$ (maximise f)



d) Exercices

EXERCICE 18: Minimisation par la méthode de Newton (1)

Soit la fonction $f(x) = x^3 + 2x^2 - 13x + 10$. On veut minimiser cette fonction.

1. rappeler les conditions nécessaires que doivent respecter un minimum.
2. trouver mathématiquement le ou les minimums de la fonction.
3. Pour chaque minimum trouvé à la question précédente, indiquer s'il est local ou global.
4. appliquer la méthode de Newton pour trouver le minimum de la fonction avec une précision $\epsilon = 10^{-6}$. On partira de $x_0 = 1$.

EXERCICE 19: Minimisation par la méthode de Newton (2)

Soit la fonction $f(x, y) = e^x + e^{-x} + e^y + e^{-y}$. On veut minimiser cette fonction.

1. Calculer ∇f et $\nabla^2 f$.
2. Appliquer la méthode de Newton en partant de $(x_0, y_0) = (1, 1)$ pour trouver le minimum de la fonction avec une précision $\epsilon = 10^{-6}$.

5.3 Méthode de quasi-Newton

a) Principe

Objectif

Conserver un modèle quadratique de f en x_k

$$\hat{f}_k(x) = f_k(x_k) + g_k^T(x - x_k) + \frac{1}{2}(x - x_k)^T H_k(x - x_k) \quad \text{avec } H_k \approx \nabla^2 f(x_k)$$

sans calculer explicitement H_k

Mise à jour de Broyden

On peut appliquer la méthode de Broyden à la résolution de $g(x) = \nabla f(x) = 0$.

$$H_k = H_{k-1} + \frac{(y_{k-1} - H_{k-1}d_{k-1})d_{k-1}^T}{d_{k-1}^T d_{k-1}} \quad \text{avec } \begin{cases} d_{k-1} = x_k - x_{k-1} \\ y_{k-1} = g(x_k) - g(x_{k-1}) \end{cases}$$

Inconvénients

- H_k n'est pas forcément symétrique
- H_k n'est pas forcément positive


Pour aller plus loin

Modifications de la méthode si l'on souhaite avoir $H_k \approx \nabla^2 f(x_k)$

Formules BFGS, DFP ou SR1 (voir le cours de Max Cerf).

b) Comparaison Newton - Quasi-Newton

- Fonction : $f(x) = -x^4 + 12x^3 - 47x^2 + 60x$
- Dérivée : $f'(x) = -4x^3 + 36x^2 - 94x + 60$
- Quasi-Newton : $h_k = \frac{f'(x_k) - f'(x_{k-1})}{x_k - x_{k-1}}$
- Point initial : $x = 3 \Rightarrow$ convergence
Autres points $\Rightarrow$ divergence ou maximum



Quasi - Newton

k	x_k	$f(x_k)$	$f'(x_k)$	h_k	Erreur
0	3,00000000	0,00000000	-6,00E+00	1,000	-4,56E-01
1	2,99900000	0,00600700	-6,01E+00	14,000	-4,57E-01
2	3,42857155	-1,31945027	-3,15E-01	13,267	-2,70E-02
3	3,45230465	-1,32362420	-3,79E-02	11,672	-3,28E-03
4	3,45554876	-1,32368634	-4,68E-04	11,527	-4,06E-05
5	3,45558934	-1,32368635	-7,27E-07	11,509	-6,32E-08
6	3,45558940	-1,32368635	-1,40E-11	11,509	-1,22E-12
7	3,45558940	-1,32368635	-5,68E-14	11,462	-4,44E-15

Newton

k	x_k	$f(x_k)$	$f'(x_k)$	$f''(x_k)$	Erreur
0	3,00000000	0,00000000	-6,00E+00	14,000	-4,56E-01
1	3,42857143	-1,31945023	-3,15E-01	11,796	-2,70E-02
2	3,45526446	-1,32368574	-3,74E-03	11,513	-3,25E-04
3	3,45558935	-1,32368635	-5,77E-07	11,509	-5,01E-08
4	3,45558940	-1,32368635	-5,68E-14	11,509	-4,88E-15

c) Exercice

EXERCICE 20: Minimisation par la méthode de quasi-Newton

Soit la fonction $f(x) = x^3 + 2x^2 - 13x + 10$. On veut minimiser cette fonction avec la méthode de quasi-Newton. On partira de $x_0 = 1$ avec un delta $\delta = 0.1$ pour le premier pas. On arrêtera l'algorithme lorsque $\varepsilon < 10^{-3}$.

6 Recherche linéaire


6.1 Principes

Problème sans contrainte : $\min_{x \in \mathbb{R}^n} f(x)$

Étapes principales

A chaque itération

- Construction d'une direction de descente d_k à partir du point x_k
- Réglage du pas de déplacement s_k suivant d_k



Étapes principales

À chaque itération :

- Construction d'une direction de descente d_k à partir du point x_k
- Réglage du pas de déplacement s_k suivant d_k

Direction de descente

d_k est une direction de descente en x_k si $\nabla f(x)_k d_k^T < 0$

La direction de descente est construite à partir du gradient et du hessien.

- **Plus forte pente** $\Rightarrow$ gradient (méthode d'ordre 1)
- **Préconditionnement** $\Rightarrow$ hessien (méthode d'ordre 2)

Pas de déplacement

Le pas de déplacement s_k suivant d_k doit vérifier $f(x + s_k d_k) < f(x_k)$

L'algorithme de recherche linéaire résout un problème de minimisation à une variable s :

- **Minimisation exacte** $\Rightarrow$ dichotomie (Fibonacci, nombre d'or, interpolation)
- **Minimisation approchée** $\Rightarrow$ règles de pas acceptable (Armijo, Goldstein, Wolfe)

6.2 Direction de descente

a) Plus forte pente

La direction de descente "naturelle" est celle du gradient = plus forte dérivée directionnelle :

$$d_k = -\nabla f(x_k)$$

Les directions successives de plus forte pente avec pas optimal sont **orthogonales**.

- Itération k


On cherche le minimum de f à partir de x_k suivant la direction $d_k = -\nabla f(x_k)$

Le nouveau point est $x_{k+1} = x_k + s d_k$ avec le pas $s > 0$ solution de :

$$\begin{aligned} \min_{s \in \mathbb{R}^k} f(x_k + s d_k) &\Rightarrow \frac{d}{ds} f(x_k + s d_k) = 0 \\ &\Rightarrow d_k^T \nabla f(x_k + s d_k) = 0 \Rightarrow d_k^T \nabla f(x_{k+1}) = 0 \end{aligned}$$

- Itération $k + 1$

La direction de plus forte pente en x_{k+1} est $d_{k+1} = -\nabla f(x_{k+1}) \Rightarrow d_k^T d_{k+1} = 0$



En effet,

$$\frac{d}{ds} f(x_k + s d_k) = \frac{d}{ds} (x_k + s d_k)^T \nabla f(x_k + s d_k) = d_k^T \nabla f(x_{k+1}) = 0.$$

Or, $d_k = -\nabla f(x_k)$, et ainsi $d_k^T d_{k+1} = 0$.

Donc les directions consécutives sont **orthogonales**.

Conséquences :


- Déplacement en zigzag
- **Convergence très lente** $\Rightarrow$ méthode inefficace en général
- Améliorations possibles $\Rightarrow$ gradient accéléré, méthode de Nesterov, préconditionnement

b) Exemple

$$f(x) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2 \Rightarrow d = -\nabla f(x) = \begin{bmatrix} -x_1 \\ -9x_2 \end{bmatrix}$$

s tel que $\min_s f(x + sd) \Rightarrow d_k^T \nabla f(x_k + sd_k) = -\nabla f(x_k)^T \cdot \nabla f(x_k + s\nabla f(x_k)) = 0$.

$$\begin{aligned} -\begin{bmatrix} -x_1 \\ -9x_2 \end{bmatrix}^T \nabla f\left(\begin{bmatrix} x_1 - sx_1 \\ x_2 - 9sx_2 \end{bmatrix}\right) &= \begin{bmatrix} x_1 \\ 9x_2 \end{bmatrix}^T \begin{bmatrix} -(x_1 - sx_1) \\ -9(x_2 - 9sx_2) \end{bmatrix} \\ &= s(x_1^2 + 729x_2^2) - (x_1^2 + 81x_2^2) = 0 \\ &\Rightarrow s = \frac{x_1^2 + 81x_2^2}{x_1^2 + 729x_2^2} \end{aligned}$$



It.	(x_1, x_2)	$f(x)$	$(d1; d2)$	s	Erreur
0	(9, 000; 1, 000)	45,000	(-9, 000; -9, 000)	0,2	9,055
1	(7, 200; -0, 800)	28,800	(-7, 200; 7, 200)	0,2	7,244
2	(5, 760; 0, 640)	18,432	(-5, 760; -5, 760)	0,2	5,795
3	(4, 608; -0, 512)	11,796	(-4, 608; 4, 608)	0,2	4,636
4	(3, 686; 0, 410)	7,550	(-3, 686; -3, 686)	0,2	3,709
5	(2, 949; -0, 328)	4,832	(-2, 949; 2, 949)	0,2	2,967
10	(0, 966; 0, 107)	0,519	(-0, 966; -0, 966)	0,2	0,972
20	(0, 104; 0, 012)	0,006	(-0, 104; -0, 104)	0,2	0,104
30	(1,11e-2; 1,24e-3)	6,90E-05	(-1,11e-2; -1,11e-2)	0,2	1,12e-2
40	(1,20e-3; 1,33e-4)	7,95E-07	(-1,20e-3; -1,20e-3)	0,2	1,20e-3
50	(1,28e-4; 1,43e-5)	9,17E-09	(-1,28e-4; -1,28e-4)	0,2	1,29e-4

Noter que si $x_1 \neq \pm 9x_2$, la valeur de s change à chaque itération.

c) Exercice

EXERCICE 21: Plus forte pente

Soit la fonction $f(x, y) = x^2 - xy + y^2 + 1$. On veut minimiser cette fonction en descendant dans la direction de plus forte pente.

1. Calculer ∇f et $\nabla^2 f$.
2. Quelle est la direction de plus forte pente ?
3. Déterminer le pas optimal de descente.
4. Utiliser la méthode descente par la plus forte pente sur 4 pas en partant de $(x_0, y_0) = (1, 2)$.
5. Utiliser la méthode descente de gradient accéléré (même point de départ).
6. Utiliser le conditionnement avec la méthode de descente par la plus forte pente sur 4 pas (même point de départ).

6.3 Gradient accéléré

a) Principe

La méthode du gradient accéléré consiste à introduire des déplacements supplémentaires.


On réalise p déplacements suivant la plus forte pente : $d_k // -g(x_k)$

$$x_0 \xrightarrow{d_0} x_1 \xrightarrow{d_1} x_2 \xrightarrow{d_2} \dots \xrightarrow{d_{p-1}} x_p$$

On réalise ensuite un déplacement suivant la direction : $d_p = x_p - x_0$.

$d_p =$ **direction moyenne** des p derniers déplacements (en général $p = n$, dimension de x).

$$x_0 \xrightarrow{d_p} x_p$$

**Justification (en dimension 2)**

- On suppose que la fonction à minimiser est une **fonction quadratique de 2 variables**.

$$f(x) = \frac{1}{2}x^T Qx + c^T x \Rightarrow g(x) = \nabla f(x) = Qx + c \Rightarrow x^* = -Qc^{-1}$$


$$\text{On a les relations : } \begin{cases} g_0 = Qx_0 + c \\ g_2 = Qx_2 + c \\ 0 = Qx^* + c \end{cases} \Rightarrow \boxed{\begin{cases} d_A = x_2 - x_0 = Q^{-1}(g_2 - g_0) \\ d^* = x^* - x_2 = -Q^{-1}g_2 \end{cases}}$$

- On considère des itérations de plus forte pente à partir du point x_0 : $d_k // g(x_k) \stackrel{\text{noté}}{=} g_k$

Les directions successives sont orthogonales :

$$\begin{aligned} \begin{cases} g_1 \perp g_0 \\ g_2 \perp g_1 \end{cases} &\Rightarrow g_2 // g_0 \\ &\Rightarrow g_2 - g_0 = \alpha g_2 \\ &\Rightarrow d_A = \alpha Q g_2^{-1} \end{aligned}$$

La propriété $g_2 // g_0$ ci-dessus n'est vrai que parce qu'on est en dimension 2 (2 variables).



- La direction d_A (de x_0 vers x_2) est parallèle à la direction d^* (de x_2 vers le minimum x^*).
Le minimum se trouve suivant la direction d_A et peut être atteint dès la troisième itération (car on est dans la fonction est quadratique).

b) Exemple

- Fonction $f(x) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2 \Rightarrow g(x) = \nabla f(x) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix} \Rightarrow H(x) = \nabla^2 f(x) = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix}$

- Minimisation suivant $d = \begin{pmatrix} d_1 \\ d_2 \end{pmatrix}$

$$f(x_s + sd) = f(x) + sd^T g(x) + \frac{1}{2}s^2 d^T H(x)d,$$

$$\text{on a } \min_s f(x_s + sd) \Rightarrow s = -\frac{d^T g}{d^T H d} = -\frac{d_1 x_1 + 9d_2 x_2}{d_1^2 + 9d_2^2}$$

- Point initial : $x_{(0)} = \begin{bmatrix} 9 \\ 1 \end{bmatrix}$

k	$x_{(k)} = (x_1; x_2)$	$f(x_{(k)})$	$d_{(k)} = (d_1; d_2)$	s	Erreur
0	(9,0000; 1,0000)	45,0000	(-9,0000; -9,0000)	0,2	9,0554
1	(7,2000; -0,8000)	28,8000	(-7,2000; 7,2000)	0,2	7,2443
2	(5,7600; 0,6400)	18,4320	(-3,2400; -0,3600)	1,8	5,7954
3	(0,0000; 0,0000)	0,0000			0,0000

- Déplacements 1 et 2

$$\begin{aligned} \text{Direction de plus forte pente : } d^{(0)} &= -g(x^{(0)}) \longrightarrow x^{(1)} \\ d^{(1)} &= -g(x^{(1)}) \longrightarrow x^{(2)} \end{aligned}$$

- Déplacement 3 suivant : $d = x^{(2)} - x^{(0)} \longrightarrow x^{(3)} = x^*$
 $x^{(3)} = x^{(2)} + s.d = x^{(2)} - d^T g / d^T H d . (x^{(2)} - x^{(0)})$

$\Rightarrow$ convergence en 3 itérations

6.4 Préconditionnement

On rappelle que dans le cas où $H(x)$ est définie positive (et donc, par Cholesky, peut s'écrire $H(x) = LL^T$ où L triangulaire inférieure), alors le conditionnement optimal de f en x est $\tilde{x} = L^T x$, ce qui implique $\tilde{H}(\tilde{x}) = I$, à savoir que le courbure est 1 dans toutes les directions.

a) Principe

- On se donne une matrice H_k **symétrique définie positive**.
 $\Rightarrow$ factorisation de Cholesky de $H_k : H_k = L_k L_k^T$
- Changement de variable : $\tilde{x}_k = L_k x_k$
- Direction de plus forte pente pour : $\tilde{f}(\tilde{x}_k) = f(x_k) = f(L_k^{-T} \tilde{x}_k)$
 $\tilde{d}_k = -\nabla \tilde{f}(\tilde{x}_k) = -\nabla f(L_k^{-T} \tilde{x}_k) = -L_k^{-1} \nabla f(L_k^{-T} \tilde{x}_k) = -L_k^{-1} \nabla f(x_k) = -L_k^{-1} d_k$
- Itération en $\tilde{x}_k : \tilde{x}_{k+1} = \tilde{x}_k - s_k \nabla \tilde{f}(\tilde{x}_k)$
- Itération en $x_k : x_{k+1} = L_k^{-T} \tilde{x}_{k+1} = L_k^{-T} (\tilde{x}_k - s_k \nabla \tilde{f}(\tilde{x}_k)) = L_k^{-T} (L_k^T x_k - s_k L_k^{-1} d_k)$
 $\Rightarrow x_{k+1} = x_k - s_k L_k^{-T} L_k^{-1} d_k = x_k - s_k H_k^{-1} d_k$
- **Le préconditionnement par la matrice H_k revient à prendre comme direction de descente**

$$d_k = -H_k^{-1} \nabla f(x_k)$$
- On vérifie que d_k est une direction de descente
 $d_k^T \nabla f(x_k) = -\nabla f(x_k)^T H_k^{-1} \nabla f(x_k) < 0$ car H_k est définie positive.

b) Utilisation

Toute matrice H_k **symétrique définie positive** convient.

Cas d'un hessien défini positif

Si le hessien $\nabla^2 f(x)$ est défini positif, on peut prendre $H_k = \nabla^2 f(x_k)$.

$$d_k = -H_k^{-1} \nabla f(x_k) = -\nabla^2 f(x_k)^{-1} \nabla f(x_k) \Rightarrow x_{k+1} = x_k - s_k \nabla^2 f(x_k)^{-1} \nabla f(x_k)$$

On obtient l'itération de Newton si le pas s_k vaut 1.

On peut prendre pour H_k **l'approximation du hessien** donnée par une méthode quasi-Newton.

Cas d'un hessien non défini positif

On peut effectuer la factorisation de Cholesky modifiée du hessien $\nabla^2 f(x_k)$

(ou de son approximation quasi Newton) pour obtenir une matrice définie positive.

On peut ajouter un multiple de l'identité : $H_k = \nabla^2 f(x_k) + \tau I$ avec $\tau > 0$ assez grand.

On peut également prendre H_k diagonale : $(H_k)_{ii} = \max\left(\varepsilon, \frac{\partial^2 f}{\partial x_i^2}(x_k)\right)$, $\varepsilon > 0$ à partir des dérivées secondes diagonales de f .


Toutes ces méthodes sont des façons de modifier le hessien afin de le rendre défini positif.

c) Exemple

- Fonction : $f(x) = \frac{1}{2}x_1^2 + \frac{9}{2}x_2^2 \Rightarrow \nabla f(x) = \begin{pmatrix} x_1 \\ 9x_2 \end{pmatrix} \Rightarrow \nabla^2 f(x) = \begin{pmatrix} 1 & 0 \\ 0 & 9 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix}^T$
- Préconditionnement : $\nabla^2 f(x) = LL^T$

$$L = \begin{pmatrix} 1 & 0 \\ 0 & 3 \end{pmatrix} \Rightarrow \begin{cases} \tilde{x}_1 = x_1 \\ \tilde{x}_2 = 3x_2 \end{cases} \Rightarrow \tilde{f}(\tilde{x}) = \frac{1}{2}\tilde{x}_1^2 + \frac{9}{2}\left(\frac{1}{3}\tilde{x}_2\right)^2 = \frac{1}{2}\tilde{x}_1^2 + \frac{1}{2}\tilde{x}_2^2$$
- Direction : $\tilde{d} = -\nabla \tilde{f}(\tilde{x}) = \begin{pmatrix} -\tilde{x}_1 \\ -\tilde{x}_2 \end{pmatrix}$
- Pas : $\min_s \tilde{f}(\tilde{x} + s\tilde{d}) \Rightarrow s = 1$

- Itération : $\tilde{x}_{k+1} = \tilde{x}_k + s_k \tilde{d}_k = 0$
 $\Rightarrow$ **convergence en 1 itération**




6.5 Pas de déplacement par minimisation exacte

On cherche à trouver un minimum local x^* avec une précision donnée (dans ce cadre, la valeur de s à choisir pour se déplacer dans la direction d)

- réduction itérative de l'intervalle de recherche (dichotomie)
- réduction optimale : Fibonacci, nombre d'or

C'est un problème à **une variable** :





a) Recherche par dichotomie

L'allure de la fonction f n'est pas connue.


On suppose qu'il existe un minimum unique dans l'intervalle de recherche $[a, d]$

- On évalue la fonction aux extrémités a et d : $\Rightarrow f(a), f(d)$
- On évalue la fonction en 2 points b et c : $a < b < c < d \rightarrow f(b), f(c)$
- On conserve soit l'intervalle $[a, c]$, soit l'intervalle $[b, d]$



Réduction optimale de l'intervalle

- On cherche b et c pour que l'intervalle restant soit le plus petit possible.
La taille de l'intervalle restant ne doit pas dépendre du choix de $[a, c]$ ou $[b, d]$.
- On note :
 Δ_1 la longueur de l'intervalle initial $\rightarrow \Delta_1 = d - a$
 Δ_2 la longueur de l'intervalle restant $\rightarrow \Delta_2 = c - a$ si on garde $[a, c]$
 $\rightarrow$ ou $\Delta_2 = d - b$ si on garde $[b, d]$




$$\Delta_2 = d - b = c - a$$

$$\Rightarrow a + d = b + c \Rightarrow \frac{a + d}{2} = \frac{b + c}{2}$$

Les points b et c doivent être symétriques par rapport au milieu de l'intervalle $[a, d]$.

- On suppose que l'intervalle restant est $[a, c]$.
- Pour réutiliser le point b à l'itération suivante, on choisit le nouveau point e symétrique de b par rapport au milieu de l'intervalle $[a, c]$.**

$$\text{On a : } \begin{cases} \Delta_1 = d - a \\ \Delta_2 = c - a = d - b \\ \Delta_3 = b - a = c - e = d - a = (d - b) + (b - a) \end{cases} \Rightarrow \Delta_1 = \Delta_2 + \Delta_3$$



Les longueurs Δ_k des intervalles successifs vérifient :

$$\Delta_k = \Delta_{k+1} + \Delta_{k+2}$$

- Les intervalles successifs sont de longueur Δ_k vérifiant : $\Delta_k = \Delta_{k+1} + \Delta_{k+2}$

- Après un nombre N d'itérations, on obtient un intervalle de longueur Δ_{N-1} .
- On définit la suite de nombres F_k par : $\Delta_k = F_{N-k}\Delta_{N-1}$ pour $k = 1, \dots, N-1$.
- La suite $(F_n)_{n=1, \dots, N-1}$ vérifie

$$\left\{ \begin{array}{l} \Delta_k = \Delta_{k+1} + \Delta_{k+2} \Rightarrow \frac{\Delta_k}{\Delta_{N-1}} = \frac{\Delta_{k+1}}{\Delta_{N-1}} + \frac{\Delta_{k+2}}{\Delta_{N-1}} \\ \Rightarrow F_{N-k} = F_{N-k-1} + F_{N-k-2} \\ \Rightarrow F_n = F_{n-1} + F_{n-2} \text{ pour } n = N-k, n = 3, 4, \dots, N-1 \\ \Delta_{N-1} = F_1 \Delta_{N-1} \text{ pour } k = N-1 \Rightarrow F_1 = 1 \end{array} \right.$$

- La suite est complètement déterminée par la valeur de F_2

$$\left\{ \begin{array}{ll} F_1 = 1 & \\ F_2 & \text{à choisir} \\ F_n = F_{n-1} + F_{n-2} & \text{pour } n = 3, 4, \dots, N-1 \end{array} \right.$$

b) Méthode de Fibonacci

La méthode de Fibonacci consiste à choisir des valeurs optimales afin de minimiser la taille de l'intervalle final.

- Pour un nombre N d'itérations fixé, on choisit F_2 pour que Δ_{N-1} soit minimal. $\Delta_{N-1} = \frac{\Delta_1}{F_{N-1}}$ minimal $\Rightarrow F_{N-1}$ maximal $\Rightarrow F_2$ maximal.
- Valeur maximale de F_2 : $\Delta_{N-1} \geq \frac{1}{2}\Delta_{N-2}$ (car $\Delta_k \geq 1\Delta_{k-1}$) $\Rightarrow F_1 \geq \frac{1}{2}F_2 \Rightarrow F_2 \text{ max} = 2$
- On obtient la suite de Fibonacci : 1, 2, 3, 5, 8, 13, 21, ...

Nombre d'itérations

- La méthode de Fibonacci est optimale si l'on fixe à l'avance la précision requise sur la solution.
- **Précision requise** : $\Delta_{N-1} = p$
Intervalle initial $[a, b]$: $\Delta_1 = b - a$
 $\Rightarrow \Delta_{N-1} = \frac{\Delta_1}{F_{N-1}} \Rightarrow F_{N-1} = \frac{b-a}{p} \Rightarrow \text{valeur de } N$

La méthode de Fibonacci donne le nombre minimal d'itérations N pour obtenir la solution avec une précision donnée.

- La disposition des premiers points b et c dépend de N : $\frac{\Delta_1}{\Delta_2} = \frac{F_{N-1}}{F_{N-2}} \rightarrow \Delta_2$

On a un intervalle initial $[a, b]$, $\Delta_1 = b - a$ (par exemple, $b = 1$ et $a = 0$).

On veut atteindre la précision $\varepsilon = 10^{-5}$, il faut atteindre l'ordre n tel que $\varepsilon \geq \frac{b-a}{n}$.

On génère une suite de type Fibonacci :

- $F_1 = 1, F_2 = 1$
- $F_k = F_{k-1} + F_{k-2}$, pour $k = 2 \dots n$.
- $\Delta_n = \Delta_1 / F_n$.
- $\Delta_k = F_{n+1-k} \Delta_n$, pour $k = 1 \dots n-1$.

La méthode de Fibonacci donne :

k	F_k	Δ_k
0	1	1
1	1	1
2	2	0,5
3	3	0,3333
4	5	0,2
5	8	0,1250
6	13	$7,692 \cdot 10^{-2}$
7	21	$4,762 \cdot 10^{-2}$
8	34	$2,941 \cdot 10^{-2}$
9	55	$1,818 \cdot 10^{-2}$
10	89	$1,124 \cdot 10^{-2}$
11	144	$6,944 \cdot 10^{-3}$

12	233	$4,292 \cdot 10^{-3}$
13	377	$2,653 \cdot 10^{-3}$
14	610	$1,639 \cdot 10^{-3}$
15	987	$1,013 \cdot 10^{-3}$
16	1 597	$6,262 \cdot 10^{-4}$
17	2 584	$3,870 \cdot 10^{-4}$
18	4 181	$2,392 \cdot 10^{-4}$
19	6 765	$1,478 \cdot 10^{-4}$
20	10 946	$9,135 \cdot 10^{-5}$
21	17 711	$5,646 \cdot 10^{-5}$
22	28 657	$3,489 \cdot 10^{-5}$
23	46 368	$2,157 \cdot 10^{-5}$
24	75 025	$1,333 \cdot 10^{-5}$

c) Méthode du nombre d'or

La méthode de Fibonacci nécessite de changer la disposition des points à chaque itération.

La disposition des points n'est optimale que pour une précision donnée.

La méthode du nombre d'or est plus générale et plus simple à mettre en œuvre.

- On impose un rapport de réduction fixe de l'intervalle à chaque itération.

$$\frac{\Delta_1}{\Delta_2} = \frac{\Delta_2}{\Delta_3} = \dots = \frac{\Delta_k}{\Delta_{k+1}} = \frac{\Delta_{k+1}}{\Delta_{k+2}} = \dots = \gamma \text{ avec } \Delta_k = \Delta_{k+1} + \Delta_{k+2}$$

$$\Rightarrow \frac{\Delta_k}{\Delta_{k+1}} = 1 + \frac{\Delta_{k+2}}{\Delta_{k+1}}$$

$$\Rightarrow \gamma = 1 + \frac{1}{\gamma} \Rightarrow \gamma^2 - \gamma - 1 = 0$$

- On obtient pour le rapport γ le nombre d'or : $\gamma = \frac{1 + \sqrt{5}}{2} \approx 1.618034$
- $\Rightarrow$ Méthode du nombre d'or (ou de la section dorée)

Optimalité

- La méthode du nombre d'or n'est pas optimale pour un nombre d'itérations donné N .
 - Pour un nombre d'itérations grand : $\lim_{N \rightarrow \infty} \frac{F_N}{F_{N-1}} = \gamma$
- $\Rightarrow$ La disposition des points de Fibonacci tend vers celle du nombre d'or.

Le rapport de réduction de l'intervalle après n itérations vaut :

- Pour la méthode de Fibonacci : $\frac{\Delta_1}{\Delta_n} = F_n$
- Pour la méthode du nombre d'or : $\frac{\Delta_1}{\Delta_n} = F_n = \gamma^{n-1}$

Nombre d'itérations

Une itération de la méthode de Fibonacci ou du nombre d'or correspond à une évaluation de f .

Rapport de réduction	Nombre d'évaluations	
	Fibonacci	Nombre d'or
10^{-2}	11	13
10^{-3}	15	18
10^{-4}	20	22
10^{-5}	25	27
10^{-6}	30	31


- Positionnement des points

$$\frac{\Delta_1}{\Delta_2} = \frac{\Delta_2}{\Delta_3} = \gamma = \frac{1 + \sqrt{5}}{2} \approx 1.618034$$

$$\Rightarrow \begin{cases} \Delta_2 = \frac{1}{\gamma} \Delta_1 = r \Delta_1 \\ \Delta_3 = \frac{1}{\gamma^2} \Delta_1 = r^2 \Delta_1 \end{cases}$$

$$\text{avec } r = \frac{1}{\gamma} = \frac{\sqrt{5} - 1}{2}$$

$$\Rightarrow \begin{cases} b = a + r^2 \Delta_1 \\ c = a + r \Delta_1 \\ d = a + \Delta_1 \end{cases}$$



- Itération

$$\text{si } f(b) < f(c) \text{ alors } \begin{cases} d \leftarrow c \\ c \leftarrow b \\ \Delta_1 \leftarrow \Delta_2 \\ b = a + r^2 \Delta_1 \end{cases}$$

$$\text{si } f(b) > f(c) \text{ alors } \begin{cases} a \leftarrow b \\ b \leftarrow c \\ \Delta_1 \leftarrow \Delta_2 \\ c = a + r \Delta_1 \end{cases}$$

d) Exemple

Minimisation de $f(x) = -x \cos(x)$, $0 \leq x \leq \frac{1}{\pi}$

- exécution :

	f	0	-0.4952	-0.5482	0
Itération 1 :	x	0	0.6000	0.9708	1.5708
	f	-0.4952	-0.5482	-0.4350	0
Itération 2 :	x	0.6000	0.9708	1.2000	1.5708
	f	-0.4952	-0.5601	-0.5482	-0.4350
Itération 3 :	x	0.6000	0.8292	0.9708	1.2000
	f	-0.4952	-0.5468	-0.5601	-0.5482
Itération 4 :	x	0.6000	0.7416	0.8292	0.9708
	f	-0.5468	-0.5601	-0.5606	-0.5482
Itération 5 :	x	0.7416	0.8292	0.8832	0.9708

- Solution : $x^* \approx 0.8832 \rightarrow f(x^*) \approx -0.5606$
au lieu de $x^* \approx 0.8603 \rightarrow f(x^*) \approx -0.5611$

6.6 Pas de déplacement par minimisation approchée

On cherche une réduction suffisante de la fonction dans la direction de descente sans déterminer précisément le minimum x^* :

- règles d'acceptation (Armijo, Goldstein, Wolfe)
- limitation du nombre d'évaluations de la fonction

a) Principe

- Il n'est pas utile de réaliser une minimisation exacte suivant la direction de descente :
→ nécessite un grand nombre d'évaluations de la fonction
→ n'apporte pas une amélioration significative loin de la solution
- On peut se contenter d'une minimisation approchée
→ **2 règles d'acceptation d'un pas de déplacement**

Notations

- x_k = point courant $\Rightarrow f(x_k)$
- d_k = direction de descente $\Rightarrow \nabla f(x_k) d_k^T < 0$
- variation de la fonction f dans la direction d_k : $\varphi(s) = f(x_k + s d_k)$, $s \geq 0$

Règles d'acceptation du pas

- **Diminution suffisante de la valeur de la fonction**
 $\Rightarrow$ condition d'Armijo ou 1^{ère} condition de Wolfe
- **Déplacement suffisant par rapport au point initial**
 $\Rightarrow$ condition de Goldstein ou 2^{ème} condition de Wolfe

b) Diminution suffisante


La fonction f doit décroître suffisamment pour accepter le pas.

- Dérivée directionnelle de f suivant la direction d_k
 $\varphi(s) = f(x_k + s d_k)$, $s \geq 0 \quad \Rightarrow \quad \varphi'(0) = \nabla f(x_k)^T d_k < 0$
- On impose une diminution proportionnelle à la dérivée directionnelle, avec $0 < \varepsilon < c_1 < 0.5$

$$\varphi(s) < \varphi(0) + c_1 s \varphi'(0) \Leftrightarrow f(x_k + s d_k) < f(x_k) + c_1 s \nabla f(x_k)^T d_k$$

On prend comme valeur typique $c_1 = 0.1$

$\Rightarrow$ Condition d'Armijo ou 1^{ère} condition de Wolfe ou 1^{ère} condition de Goldstein



c) Déplacement suffisant


Le déplacement à partir du point initial doit être suffisant pour accepter le pas.

- Condition de Goldstein (valeur typique $c_2 = 0.9$)

$$\varphi(s) > \varphi(0) + c_2 s \varphi'(0) \Leftrightarrow f(x_k + s d_k) > f(x_k) + c_2 s \nabla f(x_k)^T d_k$$

- Condition de Wolfe : réduction de la dérivée (valeur typique $c_2 = 0.9$)

$$\varphi'(s) > c_2 \varphi'(0) \Leftrightarrow \nabla f(x_k + s d_k)^T d_k > c_2 \nabla f(x_k)^T d_k$$




d) Récapitulatif

- Conditions de Goldstein :**

$$\begin{cases} \varphi(s) < \varphi(0) + c_1 s \varphi'(0) & c_1 \approx 0.1 \\ \varphi(s) > \varphi(0) + c_2 s \varphi'(0) & c_2 \approx 0.9 \end{cases}$$
 si la dérivée de f est coûteuse
- Conditions de Wolfe :**

$$\begin{cases} \varphi(s) < \varphi(0) + c_1 s \varphi'(0) & c_1 \approx 0.1 \\ \varphi'(s) > c_2 \varphi'(0) & c_2 \approx 0.9 \end{cases}$$
 si la dérivée de f est disponible
 ou également : $|\varphi'(s)| < c_2 |\varphi'(0)|$ (assure théoriquement la convergence)



e) Réglage du pas

Méthode de dichotomie

On cherche un pas s vérifiant les conditions de Goldstein :
$$\begin{cases} \varphi(s) < \varphi(0) + c_1 s \varphi'(0) \\ \varphi(s) > \varphi(0) + c_2 s \varphi'(0) \end{cases}$$

Initialisation

- Intervalle initial : $[s_{\min}, s_{\max}]$ avec $s_{\min} = 0$ et $s_{\max}$ assez grand.
- Valeur initiale : $s = 1$ (pas de Newton)

Itérations :

Évaluation de $\varphi(s)$ et comparaison aux droites de Goldstein :

- si s ne respecte pas la condition 1 $\Rightarrow$ amélioration insuffisante, pas trop grand : $s_{\max} = s$
- si s ne respecte pas la condition 2 $\Rightarrow$ déplacement insuffisant, pas trop petit : $s_{\min} = s$



Réduction de l'intervalle $[s_{\min}, s_{\max}]$

Essai suivant : $s = \frac{1}{2}(s_{\min} + s_{\max})$

Arrêt

si s respecte les 2 conditions $\Rightarrow$ le pas est acceptable.

si l'intervalle $[s_{\min}, s_{\max}]$ devient inférieur à un seuil donné.

**6.7 Algorithme complet de recherche linéaire**

Note : pour les mises à jour plus optimale du Hessien (BSGS ou SR1), se référer au cours de Max Cerf.

Principaux résultats de convergence

- Si d est une direction de descente, et f est bornée inférieurement suivant d , alors il existe un pas s suivant d vérifiant les conditions de Wolfe
- Si les directions de descente ne deviennent pas "trop" orthogonales au gradient, l'algorithme de recherche linéaire avec les **conditions de Wolfe** est **globalement convergent**.

$$\lim_{k \rightarrow \infty} \|\nabla f(x_k)\| = 0 \rightarrow \text{convergence vers un point stationnaire}$$

En pratique



- Les directions de descente peuvent être construites avec BFGS ou SR1 (si matrices $H_k > 0$)
- La valeur des coefficients de Goldstein ou Wolfe c_1 et c_2 n'est pas critique pour la convergence.
- Le pas de Newton ($s = 1$) est systématiquement testé, car il donne la solution si la fonction est proche de son modèle quadratique.
- La méthode de plus forte pente a la propriété de convergence globale, mais peut être très lente. On peut assurer la convergence globale d'un algorithme de recherche linéaire utilisant d'autres directions en effectuant périodiquement une itération de plus forte pente.

Exemple : fonction de Rosenbrock

$$f(x_1, x_2) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2$$

$$\text{Point initial : } \begin{pmatrix} -1.2 \\ 1 \end{pmatrix}$$

Recherche linéaire avec BFGS ou SR1



7 Exemple de méthode directe

7.1 Idée

Problème sans contrainte : $\min_{x \in D} f(x)$ où D est un domaine borné

- Les méthodes sans gradient (ou d'ordre 0) n'utilisent que des évaluations de la fonction.
 $\Rightarrow$ méthodes applicables à toute fonction (non dérivable, bruit numérique)

- Capacité à localiser plusieurs minima locaux (et éventuellement le **minimum global**)
- Convergence généralement lente, peu précise
→ méthodes utilisées pour initialiser un algorithme local plus précis

Principe de la méthode DIRECT (DIviding RECTangles, 1993) :

- On cherche un **minimum global** de la fonction f sur un domaine D de $\mathbb{R}^n$.
La fonction est supposée **lipschitzienne** sur D ($\Rightarrow$ bornée inférieurement).
- On partitionne progressivement le domaine de recherche D .
 - le domaine D est partitionné en sous-domaines D_j .
 - sur chaque sous-domaine, on estime un minorant de f avec une condition de type Lipschitz.
 - le sous-domaine de plus bas minorant est "potentiellement optimal".
= sous-domaine ayant le plus de chance de contenir le minimum de f
 - ce sous-domaine "potentiellement optimal" est sélectionné pour être divisé à son tour.
- $\Rightarrow$ permet de localiser les zones potentielles où se trouve le minimum global.
On peut l'utiliser pour initialiser un algorithme local de descente.
- peut être étendue au cas à n variables.

7.2 Fonction lipschitzienne

- La fonction f est supposée **lipschitzienne** (ou continue au sens de Lipschitz) sur le domaine D .
à savoir $\exists K > 0, \forall x, y \in D, \|f(y) - f(x)\| \leq K\|y - x\|$
 K est la constante de Lipschitz de la fonction f sur $D \rightarrow$ non connue *a priori*
- Une fonction f lipschitzienne sur un hyperrectangle D de $\mathbb{R}^n$ est bornée.


$$\forall x \in D, f(c) - Kd \leq f(x) \leq f(c) + Kd$$

avec :

c = point quelconque de D
 d = majorant de D
 $\Rightarrow \|x - c\| \leq d$

Ceci implique que :


$f(c) - Kd$ est un minorant de f sur D .




- Autrement dit, une fonction f est K -Lipschitzienne sur D , si en chaque point x de D , la fonction $f(x)$ à une pente inférieure ou égale à K .
 $\Rightarrow$ la variation de $f(x)$ est bornée.

7.3 Principe


1. On divise l'intervalle D en 3 parties égales.
2. On obtient des minorants aux extrémités pour chacun des intervalles.
3. Pour l'intervalle dont le minorant est le plus petit, on le subdivise en 3 en évaluant la fonction au centre de chaque intervalle.
4. Recommencer en (2) jusqu'à ce que la condition d'arrêt soit rencontrée.



Initialisation



Itération 1



Itération 2

On peut obtenir ainsi une ou plusieurs zones dans lesquelles le minimum a de la chance de se trouver.

